LLMChain

去中心化推理算力市场的收据结算与成本优化

技术白皮书

LLMChain Foundation

v3.0　2026 年 10 月

本文描述一个尚未上线的协议设计，状态为公开评审草案，参数以主网治理定稿为准。文中性能数字分三类标注：合成轨迹实测、数量级估算、设计目标，均不构成已实现系统的测量结果。代币相关内容不构成任何形式的投资邀约。

文档说明

本文给出 VSR 协议（LLMChain）的设计。

结算凭证的缺失

推理算力正在变成一种可交易资源：开源权重自托管、合规中转、聚合平台与闲散硬件共同构成供给，Agent 与应用侧按 token 计量、按调用付费。买方付钱之后，无法核对自己买到的是不是声称的模型、声称的算力；卖方只需出一张账单。

互联网流量一开始也不可交易，直到有了计量凭证与结算规则，才成为分散产生、聚合计价、按次结算的商品。算力缺的是同一类东西：一份第三方能独立核对的计量与结算凭证。没有凭证，市场只能靠平台信誉运转，离开中心化平台就无法定价、无法追责。

协议定位

协议由此定位为 **去中心化推理算力市场的防作弊结算**。链把每一次推理调用固化为一张可验证的算力收据：调用方与服务方共同签字，记载调用标识、模型摘要、输入输出摘要、证明等级与结算金额，链按收据完成结算与罚没。其上一切应用都以收据为事实依据。

三层结构与依赖方向

收据只回答这一次调用是否按声明交付、按什么价格结算。凭证立住之后，收入的分配仍没有着落：一次 Agent 任务常由多个调用串成，收入要在调用链上按约定拆开，转售加价、订阅包量、委托质押属于同一类规则。这些规则读取收据上的事实，改动频率高，随商业模式调整，因此放在合约层实现，不写进链内核。Agent 经济指的就是这一层。

收入分配之外，同样的活儿能不能干得更便宜，也是收据管不了的。去中心化的模型实例分布在不同节点，KV Cache 互不相通，调用换节点、会话换模型都要重新 prefill，重复计费的部分落在用户账单上，抵消闲散算力的价格优势。协议以段级上下文管理与轻量决策模型的任务分配压低这部分开销，该层不改收据语义。

这两层都读收据、都不改收据，依赖方向自下而上。没有收据，分账缺少事实依据，成本的变化也无法计量与结算。所以实现顺序是结算先行，其余随后：结算没有跑通时，省下的每一分成本都会被降级服务的价差吃掉。成本优化的原理与规划写在第 九 章，工程实施排在主网 Beta 之后（第 十 章）；实施可以晚，原理与验收条件不省略，因为这部分规划说明了协议在结算跑通之后还能解决哪些问题。

与 Agent 授权类的边界

市面上主打 Agent 经济、交易凭证的多数项目，处理的是操作授权：判断这笔操作是否由被授权的 Agent 发起，信任对象是授权链。本协议处理的是推理交付：判断这次调用是否运行在声明的模型上、是否按约定计价，信任对象是交付事实。授权完整的调用仍可能被降级执行，这在授权层的视野之外。若一份材料把本协议读作 Agent 支付授权协议，属于定位误读。差别在第 二 章展开。

阅读约定

降低重复计算的开销在本文中单独成章（第 九 章），以成本放大系数 α 记账。在 Agent 形合成轨迹的 token 账实测上，重复 prefill 把用户成本放大到有效生成的 2–7 倍；段级上下文管理与调度优化的设计目标是把 α 压到 2 以下。该目标是设计意图，验收以真实轨迹复测为准。决策层的参照实现是开源的 Laya，权重 Apache 2.0、推理代码 MIT，ONNX 部署约 1.7 GB、CPU 可跑（资料截至 2026 年 10 月）；任何运营方都能自持分配器，决策层不向单一服务购买分配判断。

全文术语以附录 B 为准。数字出现即带口径：合成轨迹实测、数量级估算或设计目标。参数一律写明建议区间与定稿条件。协议的局限与未闭合问题单列第 十一 章。文献列于附录 C。

目录

文档说明 i

第一章 引言 1

1.1 问题陈述 1

1.2 定位：链、合约层与成本层 2

1.3 双主线与实现顺序 3

1.4 设计目标 3

1.5 本文贡献 4

1.6 文档结构 5

第二章 背景与相关工作 6

2.1 Agent 调用的负载特征 6

2.2 定位辨析：算力结算与 Agent 交易授权 6

2.3 现有推理市场的结构性缺口 7

2.4 去中心化供给的成本缺口 8

2.5 相关工作 8

2.6 在协议栈中的位置 10

第三章 系统模型与设计原则 11

3.1 参与方 11

3.2 设计原则 12

3.3 信任假设 13

3.4 威胁模型 13

3.5 协议保证与不保证 14

第四章 协议设计 16

4.1 调用生命周期 16

4.2 VSR 收据 18

4.3 调用链与递归结算 19

4.4 支付通道 19

4.5 挂单簿 20
4.6 批量结算与数据可用性 20

第五章 保真与安全机制 21

5.1 分级保真 21
5.2 确定性执行 21
5.3 二分争议博弈 22
5.4 零知识证明的定位 22
5.5 TEE 信任根 22
5.6 审计员机制 23
5.7 机密性 23
5.8 激励相容分析 23
5.8.1 服务商：作弊的期望收益 24
5.8.2 审计员：诬告与串通 24
5.8.3 验证人：无法寻租 25
5.8.4 参数区间 25

第六章 共识与链架构 27

6.1 独立 Layer 1 的依据 27
6.2 纯质押共识 27
6.3 原生模块与预编译 28
6.4 性能预算 29
6.5 内核刻意不做的事 29

第七章 代币经济学 30

7.1 职能 30
7.2 价值流 30
7.3 费用结构 31
7.4 质押与罚没 31
7.5 价值捕获与风险 32

第八章 合约层的 Agent 经济 33

8.1 路由服务 33
8.2 多方分账 33
8.3 治理范围 34

第九章 成本优化：上下文管理与任务分配 35

9.1 成本模型：重复 prefill 的结构 35

9.2 上下文管理原理 35
9.3 决策模型的任务分配 36
9.3.1 分配层的小模型化与部署下限 37
9.3.2 分配决策的定义 37
9.3.3 参照实现：Laya 37
9.3.4 接口映射与迭代路径 38
9.3.5 分配原则 38
9.4 与结算层的接口 38
9.5 验收指标与口径声明 39

第十章 路线图 40

第十一章 局限与开放问题 41

11.1 保真机制的边界 41
11.2 证明机制的边界 41
11.3 成本优化的边界 42
11.4 经济机制的边界 42
11.5 协议与工程的开放问题 43

附录 A VSR 收据规范 45

A.1 字段语义 45
A.2 验证流程 45
A.3 授权令牌 45

附录 B 术语表 47

附录 C 参考文献 49

第一章 引言

推理算力正在成为一种可交易的资源：开源权重自托管、合规中转、聚合平台与闲散硬件共同构成供给，Agent 与应用侧的需求按 token 计量、按调用结算。算力在结构上与互联网流量相似，分散产生、聚合计价、按次结算。流量的交易规模建立在计量凭证之上，算力的交易目前缺少对应物：服务商单方面出具账单，调用方无法独立验证账单背后的事实。

本协议把结算对象收窄为一个可验证的单元：一次推理调用对应的**算力收据**。收据由调用方与服务商双方签名，记载调用事实、模型摘要、证明等级与金额，是链上结算的唯一依据。链只做两件事：验证收据、按收据划转资金。推理过程不上链，商业规则不上链，内容正确性不裁决。

1.1 问题陈述

考虑一个由 n 个调用方与 m 个服务商构成的推理市场。一次推理调用记为

$$c = (caller,\ provider,\ model,\ x,\ y,\ p,\ t), \tag{1.1}$$

依次为调用方、服务商、声明的模型、输入 x、输出 y、价格 p 与时间 t。在现有基础设施下，存在三个无法由第三方独立裁决的事实性问题：

(1) **存在性**。调用是否真的发生。这一项断言请求 x 到达了某个执行环境，该环境产生了 y，而不是服务商从缓存里吐出旧结果、或凭空捏造一个输出。存在性是另外两项的前提：调用若未发生，讨论它跑在哪个模型上、按什么价格结算都没有意义。在现有设施下，调用方只能看到服务商返回的字节流，字节流本身不携带执行证据，因此这一项无法由第三方独立裁决。

(2) **保真性**。执行是否运行在声明的 $model$ 上。这一项断言产生 y 的计算过程使用了权重摘要对应的那个模型，而不是被降级到更便宜的模型、更小的量化版本，或被跳过推理直接返回伪造输出。这是去中心化推理市场里利润最高的一处作弊点：声明旗舰模型、实际转发到成本只有其十分之一的模型，价差直接变成毛利，而调用方在输出上通常看不出差别。

(3) **结算性**。p 是否为双方约定的价格，多方参与时收入是否按约定分配。这一项断言划转金额与事先约定一致，不被中间环节截留、拖延或改写。调用链递归时更难核实：收入要沿调用标识串成的拓扑拆开，父调用完成时子调用往往已经发生，事后对账缺少事实依据。

这三个问题都不涉及输出内容是否正确。开放式生成任务的正确性在定义上就难以客观裁决，任何试图在协议层裁决内容质量的机制都会引入主观评分，进而引入可被操纵的权重。LLMChain 把目标收窄为：让算力服务的**事实**可验证，让结算 **自动**完成。

定义 1（可验证算力收据）. 对一次已完成的调用 c，VSR 收据 $R(c)$ 是由调用方与服务商双方签名的凭证，记载调用标识、模型摘要、输入输出摘要、证明等级与结算金额，并作为链上结算的唯一依据。收据一旦被聚合上链并通过验证，对应资金划转即告完成。

协议的核心约束是链上结算只依据收据。链上不传递推理过程，只传递收据；共识层不裁决服务质量，只裁决收据形式与客观失败。

1.2 定位：链、合约层与成本层

推理算力作为可交易资源，缺少的不是算力本身，而是计量与清结算的凭证。收据承担这一角色，记账规则由协议执行，不由单一平台持有。协议的全部内容分布在三层，三层回答的问题各不相同：

链：算力结算与算力收据

协议里唯一的基础对象是 VSR 收据。链验证收据的签名与形式条件，按收据划转资金，对被证实的客观失败执行罚没，并维护挂单簿与支付通道。推理过程不上链，内容正确性不裁决，商业规则也不进链。这一层落在最底下是推出来的结论：另外两层的每一个判断都要引用收据，没有它分账没有可引用的账目，成本的变化也无从计量。

合约层：Agent 经济

一次 Agent 任务由多个调用串成，收入要在调用链上按约定拆开，转售加价、订阅包量、Agent 间委托都是同一类拆法。这类规则改动频率与商业模式一样快，写进链内核意味着每次迭代都要走协议升级，因此放在合约层。合约层可以新增规则、改规则，改不动收据本身，也改不动收据是否成立的判定。

成本层：上下文与调度优化

去中心化供给的单位成本比中心化多出一块：模型实例分布在互不相通的节点上，KV Cache 不能跨节点复用，换节点、换模型都要重新 prefill，这笔重复计算落在用户账单上。协议在结算之外做段级上下文管理与任务分配，把它压下去（第 九 章）。这一层只动成本，不动事实，也不动分配规则，所以可以最后做、单独验收，做砸了不牵动底层。

三层的关系是单向依赖：成本层的任何优化不改变收据语义；合约层的任何规则不改变结算语义。反过来说，没有收据层，Agent 经济的分账就没有事实依据，成本优化的收益也无法被计量与结算。

市面上主打 Agent 经济、交易凭证的项目，多数把协议主体放在 Agent 的行为授权上：Agent 代表用户发起支付、签署交易、执行链上操作，协议判断的是该操作是否经过授权。这是一类身份与授权问题，作用域在合约层与应用层。本协议的主体是推理算力的交付事实，作用域在链本身。两者的判断标准不同：授权类以操作是否被授权为准，结算类以算力是否按声明交付、是否可被伪造为准。授权完整但模型被降级，在结

算类中仍构成违约。一次推理调用可以是 Agent 发起的，也可以是人发起的；收据只关心调用事实，不关心调用方的身份形态。若一份材料把本协议读作 Agent 支付授权协议，属于定位误读。

1.3 双主线与实现顺序

协议沿两条主线展开。主线一是收据结算，让算力可信：交付事实可验证，造假可被客观罚没，资金按事实划转。主线二是成本优化，让算力便宜：去中心化供给的重复 prefill 被上下文管理与任务分配压下去，闲散算力的低价优势真正落到用户账单上。

顺序是硬约束：结算先行，成本优化随后。理由写在第 十 章，结算没有跑通时，省下的每一分成本都会被降级服务的价差吃掉。成本节约的收益只有在按事实结算的市场上才能落到用户侧，否则被中间方以价差形式吸收。主线一的机制见第 四–七 章，主线二的原理与规划见第 九 章，工程实施排在主网 Beta 之后。

1.4 设计目标

协议设计围绕五项可检验的目标展开，后续章节的每一项机制均可回溯到其中之一。

G1　事实可验证

对声明了证明等级 t 的调用，任何第三方可以依据链上数据与公开验证算法判定该次调用是否满足等级 t 的保真条件。判定过程不依赖服务商的自我声明，不依赖平台的内部记录，也不需要协议方介入：判定所需的输入都在链上或数据可用性层，判定算法是公开的。只有服务商自己能核对的私有凭证不满足这一条。落到可检验处，是对历史收据做第三方重放，重放方与双方无关联。

G2　调用延迟与共识解耦

选择、付款与执行三个步骤不等待区块确认，调用延迟由网络与推理本身决定。这要求支付通道在调用前就位、收据在调用后批量上链，链的出块速度因此不进入用户可感的时延路径。若每次调用都发一笔链上交易，在高频低单价的负载下，交易成本会超过调用本身的费用。调用路径上一旦出现等待确认的步骤，这一条就被破坏了。

G3　客观罚没

罚没只由可机器判定的客观失败触发，不由任何评分、声誉权重或人工裁量触发。客观失败指签名无效、证明不齐、确定性复算不一致这类任何验证人都能独立复现的判据。引入主观质量评分的罚没不满足这一条，评分权重本身就是一个可被操纵的输入。每一笔罚没都要能指回一条可机器复现的判据。

G4　激励相容

在参数区间内，以次充好、诬告、串通三种行为的期望净收益为负（第 5.8 节给出

不等式）。约束的不是惩罚力度是否足够大，而是算下来是否不划算：被检出的概率乘以罚没额度，要大于作弊得到的价差。靠威慑口号维持诚实不满足这一条。验算方式是把不等式代入参数区间，逐段检查左端符号。

G5　内核最小化

协议内核只承载变化慢的机制；随商业模式快速变化的逻辑（分账规则、路由策略）留在合约层与链下。判断一个东西是否进内核，看它的变化频率是否与共识层同级：收据格式、结算语义、罚没判据进内核，定价策略、分账比例、路由算法不进。把协议做成一个大而全的平台会与这一条冲突。内核升级的触发条件只与安全性相关，是这一条的验收口径。

成本优化不在上述五项之内：它不承诺结算正确性，只影响单位算力的经济性。把它写进协议内核目标会混淆两类保证，因此单独成章、单独验收（第 九、十 章）。

1.5　本文贡献

本文相对现有公开材料提供五项具体贡献：

(1) **收据与调用链的形式规范**。给出 VSR 收据的字段定义、序列化约束与验证规则，以及递归调用场景下基于调用标识的授权模型。规范的用途是让不同实现对同一笔调用算出同一张收据：字段含义固定、编码固定、验证条件固定，争议时双方引用的是同一个对象（附录 A）。

(2) **分级保真机制及其组合**。定义 Tier 0/1/2 三级保真条件，并给出确定性复算、二分争议与随机强制 ZK 抽查三者的分工边界与触发条件。分级的原因是供给形态的证据能力不同：开源自托管能提供权重层面的核对，闭源中转只能提供执行环境层面的证据。三者组合而非择一，是因为任何单一机制在某个攻击面上都有缺口。

(3) **激励相容分析**。把造假的期望收益为负写成不等式，给出检出率、罚没率、挑战押金与审计赏金之间的参数关系，以及各等级调用对应的参数下界。不等式的作用是把“罚得够重”这类模糊判断换成可验算的条件：给定检出率，能算出使作弊无利可图的最小罚没额度。

(4) **去中心化推理的成本模型与优化规划**。刻画重复 prefill 的结构与成本放大系数 α，给出段级上下文管理、轻量决策模型调度与闲散算力接入的设计原则、目标区间与验收条件（第 九 章）。α 的用途是把“去中心化更便宜”这个说法变成可测的量：便宜多少、在哪一段便宜、优化是否生效都可以用同一个量记账。参照实现选定开源的 Laya，尚未实现的部分明确标注。

(5) **协议边界声明**。明确列出协议不解决的问题（内容正确性、跨厂商 TEE 失效的一致裁决、协议级路由等）。边界的作用是防止设计目标被默认外推：读者可以据此判断协议在哪一段承担保证、在哪一段不承担。

1.6 文档结构

第 二 章给出负载特征、定位辨析与结构性缺口，界定协议在 Agent 授权类、推理证明类与算力市场类之间的位置。缺口确定之后，第 三 章定义参与方、信任假设、威胁模型与设计原则，第 四 章描述协议本身：调用生命周期、收据、通道、挂单簿与批量结算，第 五 章给出凭什么信收据的保真机制与激励分析，第 六 章讨论这些机制落在哪条链上，包括独立 Layer 1 的论证与性能预算，第 七 章给出链自身的钱怎么转：代币职能、费用结构与罚没参数。收据立住之后，第 八 章处理收入在调用链上如何分配，第 九 章处理同样的调用如何更便宜。第 十 章按结算先行的因果顺序列出阶段目标与退出条件，第 十一 章声明协议的局限与开放问题。

第二章 背景与相关工作

2.1 Agent 调用的负载特征

与人在聊天界面中发起的推理请求相比，Agent 发起的调用在四个维度上系统性地不同，这四个维度共同决定了协议设计的取舍。

高频低单价

单个任务会触发数十至数千次推理，单次价值低到不值得为其走一次链上交易。人一天发起几十次请求，Agent 一个任务就能发起上千次，其中多数调用的费用以厘计。若每次调用都独立结算，链上交易成本会超过调用本身的费用。结算成本因此必须被聚合摊薄，调用路径上不能有等待区块确认的步骤，否则交易本身吞噬利润。

链路递归

一个任务常常调用 Agent B，B 再调用服务商 C，收入需要沿调用链分配。链路长度不可预知，父调用完成时子调用往往已经发生。事后对账缺少事实依据：收据之间若没有可验证的拓扑关系，谁该拿多少只能靠人工核对或平台私有规则。收据因此必须携带调用标识与父子关系（第 4.3 节）。

无人值守

没有人逐条核对输出。人调用时还能靠常识察觉回答不对劲，Agent 调用的结果直接进入下一个动作，降级服务的输出会被静默地继续使用。结果是否由声明的模型产生，因此只能靠机制事后可验证，不能靠人工抽查兜底（第 五 章）。

服务商异构

同一模型可能由自托管开源权重、合规中转、聚合平台等不同形态供给，可信基座不同。开源自托管可以把权重哈希公开，声明可被核对；闭源中转只能给出会话证据，证据强度取决于硬件信任根。要求所有供给方达到同一证明强度，要么把开源自托管也拖进高成本，要么把中转商放进无法核对的灰区。要求的证明强度因此必须分级而非一刀切。

高频低单价要求链下调用（G2），递归链路要求收据携带调用拓扑（第 4.3 节），无人值守要求可机器验证的保真机制（第 五 章），供给异构要求分级证明而非一刀切（第 5.1 节）。

2.2 定位辨析：算力结算与 Agent 交易授权

公开材料中两类设计常被并置，但它们回答的问题不同，混用会导致设计目标错位。本节给出判据，后续机制按此展开。

Agent 交易授权类。这类项目把协议主体放在 Agent 的身份、额度与可执行操作上：身份注册、行为授权、支付发起、链上交易签名。典型接口是 Agent 以某身份签署一笔转账。信任对象是**授权链**。只要授权链完整，操作即视为合法，操作背后的执行事实不在协议视野内。

推理算力结算类。本协议的主体是一次推理算力是否按声明交付、按约定价格结算。信任对象是 **交付事实**。授权完整但模型被降级，仍构成违约；未经授权但收据齐备的调用在本协议内不存在，因为收据由调用方共签产生。一次调用可以由 Agent 发起，也可以由人发起，收据只记录调用事实，不判断发起方的身份形态。

两类可以叠加：Agent 交易授权判定下单是否经过授权，算力结算判定下单之后买到了什么」。本协议只做后者；前者以现有标准接入（第 2.6 节）。需要点名的边界是：市面若干「Agent 经济」项目已经覆盖操作级交易授权，本协议不在该层增加新原语；若一份材料把本协议读作 Agent 支付授权协议，属于定位误读。

2.3 现有推理市场的结构性缺口

在上述负载特征下，当前推理市场在四个环节上无法自证。表 2.1 把缺口、后果与对协议的要求对应起来。

表 2.1　推理市场的结构性缺口

缺口	具体表现	后果
调用无凭证	账单由平台单方面出具，转售环节没有可追溯的结算事实	争议无法回溯，自动化分账缺乏事实依据
保真不可证	中转商可以挂旗舰模型、按三折报价、实际转发到更便宜的模型	以次充好的毛利高于被发现的期望成本
资金被托管	聚合平台先收钱后分发，调用方须信任中介的清偿能力与分配规则	引入单点对手方风险，分账规则不透明
分账无原语	A 调 B、B 调 C 的链式收入分配缺少通用机制	要么人工对账，要么绑定单一平台的私有规则

把表 2.1 的四行放在一起看，指向的是同一个断点。证明系统判定的是计算是否被正确执行，市场系统判定的是成交量是否真实，两者各自完整，中间却空着一段：按什么事实决定谁该被付、谁该被罚。这一段之所以空着，是因为它需要的对象另有形态：把「交付了什么」和「该结多少钱」绑在同一张凭证上，证明和订单都不承担这件事。没有凭证，服务商只能自报账单，转售环节没有可追溯的结算事实，分账只能靠人工对账或平台私有规则。

协议的主线一就补在这一段：把每次调用的交付事实固化为收据，以收据为唯一结算依据。收据一物两用，既记事实也记金额，两个原本分开的问题因此共用同一份可验证的对象。

2.4 去中心化供给的成本缺口

结算缺口说的是买到的是不是声明的东西。即便这一点解决了，还有一层问题：同样的东西买不买得起。去中心化算力由异构节点供给，模型实例与 KV Cache 分布在互不相通的设备上，一次长上下文调用若被调度到新节点，或在会话中途切换模型，已有的注意力状态无法直接复用，输入序列要重新 prefill。中心化服务端用前缀缓存把这笔开销吸收在自己账上，去中心化市场没有这层缓存可借，它直接落到用户账单上。

对 Agent 形工作负载的 token 账实测（合成轨迹，详见第 九 章的口径声明）给出了四类放大：全量重喂相对有效生成约 3.94 倍（合成轨迹实测，下同）；可复用前缀位于 scratchpad 中部而非尾部时约 2.47 倍；会话中途切换模型实例平均约 3.45 倍、最坏约 7.05 倍；分叉式重试的重复前缀约 2.26 倍。这些数字是代理指标而非市场报价，但方向明确：去中心化供给的价格优势会被重复 prefill 部分抵消，抵消程度取决于上下文管理与调度质量。

协议的主线二即针对这一段：以段级上下文管理与轻量决策模型的任务分配压低成本放大系数 α（第 九 章）。两条主线的关系是前提而非并列：成本节约的收益只有在按事实结算的市场上才能落到用户侧，因此实现顺序是结算先行。

2.5 相关工作

按机制归类，已有工作分布在四个方向。表 2.2 给出能力对照；需要说明的是，各项目的定位与能力随版本演进，本文对照以 2026 年 10 月公开资料为准，且只比较机制类别，不评价实现质量。

Agent 授权类。以 x402 的机器可发起支付 [9] 与 ERC-8004 的 Agent 身份声誉注册 [10] 为代表，判定 Agent 的身份、可用额度与可发起的操作。这类工作位于授权层，其规范文本不覆盖调用是否按声明发生，也不覆盖多方之间如何结清。本协议在两者之下补交付事实与结算一段，不要求调用方更换支付方式或身份体系，也不在授权层增加新原语。

推理证明类。以 zkML、乐观验证、可信执行环境为代表的路线，判定这次计算是否被正确执行。代表工作包括 Gensyn 的可复现计算库 RepOps 与链下计算市场 [5]、基于 zkSNARK 的推理证明工程（如 ezkl 等） [6]，以及交互式验证的经典结果 TrueBit [2]。这一路线的证明成本或延迟至今仍是大规模每次推理出证明的主要障碍；更重要的是，即使证明交付，谁该被付钱、谁该被罚没不在其结算语义内。

算力市场类。以去中心化算力与推理交易量为卖点的网络（如 Akash [7]、io.net、Bittensor [8] 等）已经承载真实成交量，但服务是否按声明的模型与价格发生，一般不设独立验证层；Bittensor 以子网评分与排放作为激励信号，评分权重本身构成一个需要被信任的主观维度。本协议不把服务量计入共识权重，动机正在于此（原则 2，第 3.2 节）。

决策层的开源参照。第 九 章的任务分配按 System One 型决策模型的能力类别定义接口。该类别的公开实现中，Laya（Convai Innovations）提供编码器加决策头的结构化输

表 2.2　能力对照（按机制类别，资料日期 2026 年 10 月）

	LLMChain	**Agent 授权类**	**推理证明类**	**算力市场类**	**中心化聚合**
结算对象	单次调用 VSR 收据	被授权的操作 / 交易	可供合约查询的证明输出	平台账单 / 作业结算	平台账单
资金托管	非托管通道，调用方直连服务商	依授权规则，多在合约层	不涉及资金结算	链上或平台托管	平台托管
共识与收益	共识权重只来自质押；收益只来自用户付费	不适用（授权层）	不适用（预言机或计算网络）	多数把有用工作纳入激励	不适用
防以次充好	分级保真 + 确定性复算 + 隐蔽挑战 + 罚没	不在作用域内（管授权不管交付）	zkML 或交互式证明，验证计算正确性	多数不验证模型身份	依赖平台信誉
递归分账	收据调用链 + 合约层分账	可承载额度控制，不产交付事实	不涉及	不涉及	平台私有规则

出与校准概率，权重 Apache 2.0、推理代码 MIT，ONNX 部署约 1.7 GB、Apple 芯片 CPU 上三问约 140 ms（官方实测，模型预热后）；Strands Decider 2B （AWS，2026 年 10 月 1 日发布）给出 2B 级躯干加指针头的对照形态，权重与训练脚本开源。两者的接口与实测口径均以 2026 年 10 月公开资料为准，用途的区分见第 9.3 节。

2.6 在协议栈中的位置

图 2.1 给出分层关系，按第 1.2 节的三层定位排列：合约层承载 Agent 经济，链承载算力结算，成本优化是横跨供给侧的增值层。身份层与支付层是可插拔的现有标准；本协议的独占层是收据与结算，以及支撑它的保真机制。任何在 ERC-8004 注册的 Agent、任何走 x402 通道的付款，都可以接入 VSR 结算而不需要经过特定应用；已有的 Agent 应用商店是第一个客户，不是协议入口。



图 2.1　协议栈位置。合约层承载 Agent 经济，身份与支付是可插拔的现有标准；收据结算与保真机制为链的独占层，底层由专用 L1 承载；成本优化是增值层，不改收据语义（第 九 章）。

与推理证明预言机路线相比，本协议不追求把证明输出供外部合约消费，而是把证明作为收据结算的前置条件；与算力市场路线相比，本协议不把服务量当作激励分配依据。定位上的差别决定了机制上的差别，后续章节按此展开。

第三章 系统模型与设计原则

3.1 参与方

协议涉及六类角色，其职责、质押要求与收益来源汇总于表 3.1。同一主体可以兼任多个角色，但职责边界在协议内是分离的，尤其是审计与裁决两项权力不集中于同一角色（第 5.6 节）。

表 3.1 参与方职责与经济关系

角色	职责	质押	收益来源
调用方 Caller	发起调用、验签收据、支付	通道预锁资金	消费推理服务
服务商 Provider	执行推理、签发收据、应答挑战	必需（准入下限）	调用费
审计员 Auditor	发起隐蔽挑战、提交证据	必需（挑战资格）	罚没赏金
验证人 Validator	出块、客观裁决、执行结算与罚没	必需（共识权重）	出块奖励与协议费分成
路由服务 Router	编排选商、重试、健康度数据	无	链下商业收入
委托人 Delegator	委托质押给验证人或服务商	随被委托方	按比例分享收益

调用方

付费的一方，可以是终端用户，也可以是再转售结果的 Agent。它的职责被刻意收窄：不被要求验证输出内容，只验证收据的形式与结算金额。收窄是必要的，要求调用方验证内容等于把协议的正确性建立在调用方的鉴别能力上，与无人值守的负载特征冲突。调用方的保护来自保真机制，不来自自己的核对。

服务商

供给的一方，分为两类形态：开源权重自托管，以及闭源模型中转。前者是网络的核心供给，权重哈希公开、声明可被核对；后者是许可制附加模块，必须达到 Tier 2 保真条件（第 5.1 节），因为它给不出权重层面的证据，只能给执行环境层面的证据。两类形态在同一挂单簿上竞争，价差反映的是保真等级的差异。

审计员

负责发现问题与提交证据，不参与裁决。收益是赏金，成本是挑战押金与举证开销，这个结构使审计成为有利可图时才发生的市场行为，不是协议方的例行检查。挑战与真实调用在服务商视角下不可区分（假设 5），否则服务商可以对审计请求特殊对

待。

验证人

只对客观事实做机器判定：签名是否有效、证据是否齐备、收据是否满足其声明等级的形式条件。验证人无权对服务质量打分，这条边界是硬的：一旦可以打分，评分权重就成了可被操纵的输入，G3 客观罚没不再成立。验证人的收益来自协议费，与它判定的收据金额无关，避免偏向大额收据。

路由服务

面向调用方提供统一接口（可实现为 OpenAI 兼容格式），链下完成查挂单、选商、重试。它是协议之上的商业层，不是协议组件：不经手资金，收益不进入收据结算，也不能影响服务商的保真等级。作用是降低接入成本，高级调用方可以绕过它直连协议。

委托人

把质押委托给验证人或服务商，分享收益的同时承担被罚没的连带风险。这一角色让资本供给与节点运维分离：有资本的不必自己运行节点，有节点的不必自备全部质押。连带责任是必须的，否则被委托方可以把他人的质押当作自己的安全预算。

3.2 设计原则

以下五条原则是机制取舍的判据。凡是与原则冲突的特性，无论需求强度，不进入协议内核。第 9.3.5 节另给出成本层的两条原则，约束对象不同，与本节五条不冲突。

原则 1（收据即结算）. 链上唯一的业务对象是 VSR 收据。收据被验证即触发资金划转，不存在与收据平行的、需要另行仲裁的结算流程。推理过程不搬运上链。

原则 2（服务量不进入共识权重）. 共识权重只来自质押。服务商的调用量、收入、用户评分都不影响其在共识中的地位。这一条隔离了两类风险：用刷量换取记账权，以及用评分操纵收益分配。

原则 3（只客观罚没）. 罚没触发条件必须是可机器判定的客观失败：签名不符、转发证据缺失、确定性复算不一致、争议收敛后的单步验证失败。主观评分、声誉加权、人工裁量不触发罚没。

原则 4（链下热路径，链上冷路径）. 选择、付款、执行在链下完成，不受区块间隔约束；链上只承载挂单更新、通道开关、收据聚合与结算。被服务商拒绝的请求不产生收据，不消耗链上资源。

原则 5（内核最小化）. 协议内核只承载变化慢的机制：准入、收据、通道、挂单、保真与罚没。分账规则、路由策略、应用计费等随商业模式快速变化的逻辑留在合约层与链下，由社区迭代，不以硬分叉为代价。

3.3 信任假设

协议的安全性建立在以下假设之上。每条假设都在后文标注其被依赖的位置；假设不成立时的后果集中列于第 十一 章。

假设 1（底层共识安全）. 链的共识算法保证活性与安全性（在既定容错阈值内），交易与收据在最终确认后不可逆。

假设 2（密码学原语可靠）. 所用签名方案不可伪造，摘要函数抗碰撞，随机数信标在协议使用处不可被单一参与方预测或操纵。

假设 3（TEE 未被攻破时的完整性）. 在厂商信任根未被绕过的前提下，TEE 远程证明报告不可伪造，enclave 内执行的代码与数据对宿主不可篡改、不可窥视。TEE 被攻破的场景由随机强制 ZK 抽查兜底（第 5.4 节），但兜底提高的是检出率，不是绝对安全。

假设 4（经济理性）. 参与方以期望净收益最大化行事。非理性破坏（不为收益的作恶）不被协议防御，只影响作恶者自身收益。

假设 5（挑战不可区分性）. 在适当实现下，审计员发起的挑战请求与真实调用在服务商可观测的信息上不可区分。若服务商能可靠识别挑战，隐蔽性失效，检出率 p 的分析随之失效。

3.4 威胁模型

考虑以下五类攻击者，其余攻击面不在本协议的防御范围内。

(1) **降级服务商**。动机是价差：声明旗舰模型、实际跑更便宜的模型或直接返回伪造输出，毛利立刻增加。它控制一台推理服务器，可任意处理其收到的请求，可与同谋串通；但不能伪造他人签名，不能破坏密码学原语。它攻击的是保真性，是本协议防御的首要对象。

(2) **不诚实中转商**。动机同样是价差，但作弊位置在上游：声称调用了闭源上游，实际未调用或调用了更便宜的上游。它完全控制自己的宿主环境，可能尝试攻击自身 TEE（即假设 3 失效的场景），并伪造 TLS 会话证据。与降级服务商的区别在于证据形态不同：它给不出权重，只能给执行环境证据，因此必须达到更高的保真等级。

(3) **恶意审计员**。动机是赏金：诬告诚实服务商骗取罚没分成，或与服务商串通制造虚假挑战，把罚没收益在两者之间转移。它可发起任意次数挑战，须支付挑战押金。它攻击的是裁决过程本身，而不是交付事实，因此防御放在押金与裁决权的分离上。

(4) **串通验证人**。动机是偏袒：操纵结算或罚没结果，让自己关联的服务商多拿钱或少被罚。它在共识容错阈值内可以合谋；超出阈值的攻击属于假设 1 的失效场景，不在本协议的防御承诺内。防御的着力点是让验证人拿不到评分权，使操纵没有可作用的杠杆。

(5) **赖账调用方**。动机是省钱：拿到推理结果后拒绝付款，或对已结算的收据提出虚假争议。它控制自身客户端行为，须受通道资金约束。防御放在预锁资金上，使拒付在协议内没有可执行的动作。

表 3.2 给出攻击与防御机制的对应关系。每一项防御在第 五 章展开；残余风险一列如实标注防御不完全之处。

表 3.2　主要攻击与防御

攻击	防御机制	残余风险
以小模型冒充大模型	确定性复算输出必须逐位一致；不一致触发二分争议与罚没	仅适用于可确定性执行的模型与算子集
伪造上游调用（闭源中转）	TEE 内记录 TLS 会话证据；拿不出即视为客观违约	依赖 TEE 与厂商信任根
攻破 TEE 后长期作弊	随机强制 ZK 抽查，使作弊期望收益为负	抽查率 ρ 与证明成本的权衡
识别并特殊对待审计请求	挑战与真实调用不可区分（假设 5）	侧信道实现不当会削弱不可区分性
审计员诬告	审计员无裁决权；挑战失败扣除押金；裁决由客观逻辑执行	呆滞的挑战占用验证资源
验证人串通操纵收益	服务收益只由用户付费决定，验证人无评分权；越界行为属共识罚没	共识层合谋超出本协议范围
调用方拒付	支付通道预锁资金，收据签发即结算	通道余额耗尽后的调用被拒绝

3.5 协议保证与不保证

协议对声明了证明等级 t 的调用提供如下保证：

- 收据中的模型声明、金额与双方签名在结算前经过验证，伪造收据无法结算。账本由此是真实的：链上每一笔划转都对应一张双方签过字的收据，不存在无收据的资金流动，也不存在收据被单方面改写的情况。
- 等级 t 所要求的保真条件若被证实不满足，对应服务商在质押额度内被罚没，赏金按规则分配给举证方。事后追责因此可用：发现作弊不需要协议方介入，任何能提交证据的人都能触发，罚没额度有质押托底，不是账面处罚。

- 资金划转以收据为唯一依据，不由平台、路由服务或任何中介代管。资金路径因此是非托管的：中介的清偿能力、分配规则、经营状况都不进入结算路径，中介倒闭不导致已交付的调用收不到钱。
- 递归调用中，子调用的授权关系可由调用链验证，分账由合约层规则执行。调用拓扑因此可追溯：A 委托 B、B 调用 C 的链路在收据上有据可查，分账规则引用的是同一份事实，争议时不需要重新取证。

协议不提供以下保证，任何将其理解为协议目标的预期都不成立：

- 不保证输出内容的正确性、安全性或合规性。开放式生成的对错在定义上就难以客观裁决，一旦协议开始裁决内容，就必然引入主观评分。内容审查是应用层的事。
- 不保证 Tier 0 调用的模型身份事后可验证。该等级不附证明，只记录声明，依赖的是事后抽查与经济威慑：作弊被发现时罚没，不作弊时省掉证明开销。要求该等级事后可证，等于要求零成本的证明，这在当前的证明技术下不成立。
- 不保证机密性，除非调用方显式选择机密级服务商（第 5.7 节）。完整性与机密性是两种保证，协议默认覆盖前者，后者要付出额外成本，由调用方自行决定是否购买。
- 不保证跨厂商 TEE 同时失效时的一致裁决（第 5.5 节）。两家厂商的信任根同时被绕过时，不同厂商的证据会互相矛盾，协议没有一个客观判据去裁定谁在说谎。这一段留作开放问题，不以假设掩盖。
- 不提供协议级智能路由与故障转移，冗余由链下路由服务实现。路由需要健康度数据、时延估计与商业策略，这些进内核会破坏可验证性与最小性（原则 5）。

第四章 协议设计

4.1 调用生命周期

一次调用的完整生命周期由七个状态与两类终止态构成。状态迁移由谁触发、是否需要上链，列于表 4.1；图 4.1 给出状态机。跨角色的端到端流程（注册、通道、调用、结算、审计五个环节）见图 4.2。

定义 2（调用状态机）. 一次调用 c 的状态集合为

$$\mathcal{S} = \{\,\mathsf{Init},\ \mathsf{Selected},\ \mathsf{Dispatched},\ \mathsf{Executed},\ \mathsf{Issued},\ \mathsf{Settled},\ \mathsf{Disputed},\ \mathsf{Aborted}\,\},$$

其中 Settled 为成功终止态，Aborted 为失败终止态，Disputed 进入争议流程后仍收敛到 Settled 或触发罚没。

表 4.1 调用状态与迁移

状态	含义	触发方	是否上链
Init	通道已开设、资金已预锁，调用标识已生成	调用方	通道开设上链
Selected	在挂单簿选定服务商与证明等级	调用方	否
Dispatched	请求发出，服务商链下决定是否接单	双方	否
Executed	推理完成，输出与签名返回	服务商	否
Issued	双方签署 VSR 收据	双方	否
Settled	收据聚合上链，验证通过，资金划转	验证人	是
Disputed	审计员挑战，进入证据提交或二分争议	审计员	是
Aborted	拒单或超时，无收据、无费用、无链上记录	服务商/超时	否

其中几处设计值得单独说明。

延迟与共识解耦。 Init 到 Issued 全部在链下完成。调用延迟由挂单簿查询、网络往返与推理本身决定，不包含区块确认。收据的最终性以聚合提交后的区块确认为准，与调用延迟是两个不同时钟。

失败不落链。 服务商拒单或超时直接进入 Aborted：不产生收据、不产生费用、不消耗链上资源。调用方切换到下一候选服务商即可，切换逻辑可由路由服务自动完成。

批量结算。 高频场景下，收据不必逐张上链。服务商可在通道生命周期内聚合收据，构造 Merkle 根批量提交，由预编译批量验签后统一结算。聚合降低单张收据的摊销成本，代价是结算延迟；提交节奏由服务商自选，但受最大间隔约束（第 4.6 节），防止服务商无限拖延结算。



图 4.1　调用状态机。链下热路径为 Init → Selected → Dispatched → Executed → Issued，全程不等区块确认；只有 Settled 与 Disputed 的裁决结果上链。



图 4.2　端到端协议流程。阶段零与阶段一中的通道开设各只发生一次；阶段一的服务循环可重复任意多次；阶段二与阶段三并行，审计不打扰用户、不冻结同一服务商的其他收据结算。

争议与结算并行。进入 Disputed 的收据不阻塞同一服务商的其他收据结算。挑战针对的是特定收据的客观失败，不冻结服务商的整体业务；但多次挑战成立会累积罚没并触发准入复审。

4.2 VSR 收据

收据是协议的核心对象。定义 1 给出概念，表 4.2 给出字段级规范，完整语义与序列化约束列于附录 A。

表 4.2　VSR 收据核心字段

字段	类型	含义与约束
`chainId` / `version`	整数 / 整数	链标识与收据格式版本，防跨链重放
`callId`	32 字节	本次调用唯一标识，由调用方生成
`parentCallId`	32 字节，可空	父调用标识，递归调用时非空
`rootCallId`	32 字节	调用链根标识，非递归调用时等于 `callId`
`caller` / `provider`	地址	调用方与服务商的链上地址
`modelHash`	32 字节	声明模型的权重哈希；闭源中转为中转声明哈希
`proofTier`	枚举	保真等级 $t \in \{0,1,2\}$，结算与罚没按此执行
`inputDigest` / `outputDigest`	32 字节	输入输出摘要，不含明文
`amount` / `asset`	整数 / 地址	结算金额与结算资产
`issuedAt` / `expiresAt`	时间戳	签发时间与结算截止时间
`authToken`	可变长，可空	父调用方签署的授权令牌，递归调用时必需
`sigCaller` / `sigProvider`	签名	双方签名，覆盖上述全部字段

验证规则。收据进入结算前，`receipt` 模块执行四项检查：双方签名有效；结算金额不超过通道内已预锁余额；`proofTier` 不高于服务商挂单声明的等级；递归收据的 `authToken` 与调用链授权关系一致。四项检查全部通过才触发资金划转。

摘要而非明文。收据只记录输入输出的密码学摘要，不记录明文。需要事后复算或争议验证时，由举证方提交原始数据，链上只校验其摘要与收据一致。这一设计同时保护调用方数据隐私与链上存储成本。

过期与防重放。`expiresAt` 之后未提交的收据失效，防止服务商长期囤积收据择机结算；`callId` 全局唯一，重复提交被拒绝。签名覆盖 `chainId`，防止跨链重放。

4.3 调用链与递归结算

Agent 的任务链表现为调用树：用户任务触发 Agent A 的调用，A 调用 Agent B，B 调用模型服务商 C。每次调用独立生成收据，通过调用标识关联为树形结构。

授权锚点取调用标识。子调用发生时父调用尚未完成、父收据尚未签发，因此子收据无法引用父收据的哈希。协议改用 `callId` / `parentCallId` / `rootCallId` 三元组加授权令牌：父调用方在发起子调用前签署 `authToken`，授权子调用记入本次任务的调用链；`receipt` 模块在子收据结算时验证令牌签名与链上授权关系。

分账在合约层。调用链给出的是**事实**：谁在谁的授权下、以什么价格、调用了谁。收入按何种比例在 A、B、C 之间分配是**规则**，规则随商业模式变化快，因此放在合约层（原则 5）。分账合约读取以 `rootCallId` 为根的收据链，按部署时约定的规则分配资金。社区可以发布新的分账标准而无需修改协议。

4.4 支付通道

调用方与服务商之间使用双向预锁通道，机制上继承支付通道的成熟设计 [3]，并对接 x402 的机器支付语义 [9]。通道生命周期为：

(1) **开设**。调用方向通道合约存入额度 D，合约锁定资金并公布通道状态；服务商的挂单声明其接受的结算资产。开设是一次链上交易，之后的调用不再等待确认。额度 D 是调用方的支付上限，也是服务商能看到的偿付能力。

(2) **链下记账**。每次调用签发收据，收据金额从 D 中累减。双方各自维护本地余额视图，无需每次上链。记账的依据是收据本身，不是任一方的流水：双方签的是同一张收据，本地视图不一致时以收据为准。

(3) **结算**。收据逐张或聚合提交上链，`channel` 模块验证后按收据金额释放资金。聚合是为了摊薄 gas：单张收据的链上成本摊销后见第 6.4 节。验证内容与第 4.6 节的收据校验一致，不额外引入结算专用判据。

(4) **关闭**。双方签署最终余额，或在一方离线时按挑战期规则强制关闭。未结算的有效收据在关闭前仍可提交，因此关闭不构成拒付窗口。挑战期的作用是给离线方留出提交收据与提出争议的时间。

拒付的处理。调用方在 Issued 之后拒付在协议内不成立：收据签发即结算，资金来源是已预锁的通道余额，不存在事后支付的环节。调用方能做的最坏行为是拒绝开设通道或要求压低额度，这由市场定价解决，不构成协议风险。通道解决的是拒付，不解决拒签收据（收据共签的公平交换问题），后者见第 11.5 节。

余额耗尽。通道余额低于下一次调用报价时，服务商可以拒绝接单（进入 Aborted）。路由服务可以实现自动补充额度，但补充动作是新的链上交易，属于冷路径。

4.5 挂单簿

`market` 模块维护链上可查询的服务目录。它与交易内存池在语义上不同：内存池中的交易被打包后消失，挂单是持久状态，持续有效直到服务商自己更新或撤下。

挂单记录至少包含：服务商地址、模型哈希、单价与计价单位、声明的证明等级、容量参考值、是否提供机密级执行、结算资产、佣金或手续费字段（若适用）。

验证人只在注册时把关一次。挂单由服务商自主声明。验证人仅在注册环节校验质押与远程证明，之后不逐单审核报价与容量的真实性。真实性交给市场纠偏：调用方用脚投票，复购与历史表现形成非协议内的信誉信息。

容量是参考值。挂单中的容量字段取上次同步时的数值，允许滞后。真正的接单裁决在请求到达时由服务商链下做出，这正是热路径不需要等待链的原因（原则 4）。

4.6 批量结算与数据可用性

聚合提交。高频服务商可以将一个通道周期内的收据构造为 Merkle 树，只提交根与批量签名。`receipt` 模块的预编译验证批量签名与根，逐张收据的明细由需要时提供 Merkle 证明。单张收据的链上成本由完整签名与全部字段降为聚合树中的一个位置，数量级估算见第 6.4 节。

最大提交间隔。服务商可以自选提交节奏，但存在最大间隔 $T_{\max}$（目标值 24 小时，定稿条件：测试网对聚合收益与结算延迟的实测权衡）。超过 $T_{\max}$ 未提交视为违约，触发罚没。这一约束防止服务商无限拖延结算，同时允许其在低峰期批量提交以节省成本。

数据可用性。收据明细归档到数据可用性层（链上 blob 或外部 DA 网络，如 Celestia 一类的方案 [11]）。归档不参与共识验证，只保证需要复算或争议时数据可获取。协议固定明细可获取这一接口，不绑定具体 DA 实现。

第五章 保真与安全机制

5.1 分级保真

不同调用对信任的要求不同。强制全部调用使用最高证明强度会把供给压缩到只有少数大玩家能承担，反而抬高价格、削弱网络效应。协议把保真证明分为三级，服务商在挂单时声明支持的等级，调用方按需选择，等级写入收据的 `proofTier` 字段并直接决定结算与罚没规则。

表 5.1 保真等级

等级	保真条件	适用场景
Tier 0	双方签名收据 + 质押担保；事后由审计员隐蔽挑战发现违约	低单价、高频调用；服务商起步接入
Tier 1	Tier 0 条件之上增加抽样指纹与强制确定性复算：抽样重放的输出必须逐位一致	开源权重自托管的默认等级
Tier 2	Tier 1 条件之上增加 TEE 远程证明（执行或上游转发在 enclave 内完成），并叠加随机强制 ZK 抽查	闭源模型中转（强制），高价值调用（可选）

两类供给形态。开源权重自托管是网络的核心供给：权重哈希公开、声明可被第三方核对，从 Tier 0/1 起步即可接入。闭源模型中转是可插拔的许可制附加模块，必须达到 Tier 2：向上游的真实转发必须在 TEE 内完成，enclave 记录 TLS 会话证据；审计员可随时发起隐蔽挑战，服务商拿不出转发证据即触发客观违约罚没。

等级与经济参数联动。等级不只是标签。罚没比例、挑战强度与随机抽查率随等级升高（表 5.2），其取值依据见第 5.8 节的激励分析：高价值调用的降级毛利更大，需要更高的检出率或更高的罚没率才能让造假的期望收益为负。

5.2 确定性执行

早期设计以 top-k 对数概率分布的统计容差作为模型指纹判据。该方法有一个无法回避的参数化困境：容差阈值缺少可靠的定量校准，设得松会放过作弊，设得紧会误罚诚实服务商，而误罚的代价是供给流失。协议不再把统计指纹作为罚没依据，改为三项机制的组合，其中第一项直接借鉴 Gensyn RepOps 的可复现计算思路 [5]。

强制确定性执行。协议约束参与 Tier 1 复算的算子实现与执行顺序：相同输入在相同模型上必须产生逐位一致的输出。判定从偏差是否落在容差内变成结果是否一致，是二

值的、客观的、可复现的，符合原则 3。统计指纹保留为辅助信号，只用于触发怀疑，不作为罚没依据。

确定性的适用范围有边界：非确定性算子（部分原子加、特定注意力实现）需要固定到确定性实现，浮点归约顺序必须锁定。协议规定可确定性执行的模型与算子集清单并随实现演进；清单之外的模型只能挂更低等级，或走 Tier 2。

5.3 二分争议博弈

确定性复算给出二值判定，但判定本身可能出错：复算环境与原执行环境的差异、恶意举证都可能造成误判。协议引入二分争议作为申诉机制，思路沿用乐观验证的经典交互式欺诈证明 [2, 4]，并适配 TEE 场景下的执行轨迹。

流程为：挑战方声称某收据的输出不正确，双方对完整执行轨迹逐轮二分，各持一半轨迹的承诺；分歧收敛到单个计算步骤后，链上只验证这一步的转移函数与双方承诺是否一致。单步验证成本与模型大小无关，复杂案件被拆到链上可负担的粒度。

该机制把单次裁决的误判成本压低：误判只影响一个步骤，不再牵连整张收据。链上验证开销也随之从 O(推理量) 降到 $O(\log$ 推理量$)$ 的交互轮数加单步验证。

5.4 零知识证明的定位

对大模型的每次推理生成零知识证明（zkML）目前在证明成本与延迟上都不适合做默认路径。协议把 ZK 放在主路径之外的三处，覆盖的调用量小，但会改变服务商的作弊权衡。

(1) **随机强制抽查**。协议按随机数信标选中少量 Tier 2 调用，要求服务商在规定时限内补交该次推理的 ZK 证明，由 `proof` 模块的验证预编译链上校验。服务商无法预判哪次会被抽中，攻破一个 enclave 之后长期稳定作弊的做法不再成立。抽查率 ρ 是安全参数：它直接进入作弊被检出的概率（第 5.8 节）。

(2) **争议的最终一步**。二分争议收敛到单个计算步骤后，该步骤可以用 ZK 证明在链上验证，避免对可疑环境的重新执行。单步证明的对象是一个算子，不是一次完整推理，证明大小因此远低于完整推理证明，这是它能进争议路径的原因。

(3) **可选最高保证**。对小模型或高价值调用，调用方可以要求每次调用附带 ZK 证明，费用由调用方承担。该选项把证明成本内部化到需求侧：谁需要最强保证谁付费，服务商不必为所有调用承担同一代价。

证明系统与电路选型尚未定稿。协议只固定证明的验证接口，即验证器接受的证明格式与公共输入约定，不绑定具体证明系统，以便随 zkML 成本下降逐步扩大适用范围。

5.5 TEE 信任根

Tier 2 目前依赖单一厂商的可信执行环境。路线图上，协议将在现有信任根之外至少再支持一种机密计算基座（AMD SEV-SNP 或机密 GPU 远程证明），使供给不被单

一厂商的供应链风险锁定。

接第二家厂商的难度有限；真正困难的是跨厂商失效时的一致裁决：当某厂商爆出漏洞、大规模撤销证书时，链如何在不停机、不误罚诚实服务商的前提下降级运行。可能的方向包括分级降级（受影响 attestation 类型的收据转为挑战期延长而非立即罚没）、时间窗缓冲、治理触发的紧急参数调整，但完整方案尚未形成。协议不会在实现之前宣称已解决该问题；它排在递归结算旗舰演示之后，不阻塞主线（第 十一 章）。

5.6 审计员机制

审计与裁决分离是激励设计的关键。若审计员可以自行裁定挑战输赢，就有动机诬告诚实服务商（骗取赏金）或与服务商串通（放水换回扣）。协议的分离方式是：审计员只负责发起隐蔽挑战与提交证据，裁决由客观的链上逻辑执行，赏金只在挑战成立后由罚没所得支付。

隐蔽挑战。挑战请求以真实调用的形式发出，与真实调用在服务商可观测的信息上不可区分（假设 5）。服务商无法识别哪些请求是审计探测，因而无法只对挑战者表现出诚实行为。

挑战押金。发起挑战须支付押金 b。挑战成立时押金退还并分享罚没赏金；挑战失败时押金被部分或全部扣除，补偿服务商的举证成本并抑制骚扰性挑战。

赏金来源。罚没所得的一部分（比例 β，见表 5.2）分配给举证成立的审计员，剩余部分进入协议金库或销毁。赏金来自罚没而非增发，使审计员的收益与网络的诚信状况同向。

5.7 机密性

保真证明保证的是**执行完整性**，即执行的确实是声明的模型，不涉及 prompt 的机密性。二者是不同维度的保证，协议将其拆开提供。需要机密性的调用可以选择机密级服务商：该类服务商必须提供 CPU/GPU 联合远程证明，机密请求只路由到具备该能力的节点，且启用相应等级的 attestation 与传输加密。

不需要机密性的普通调用，其完整性由保真证明、隐蔽挑战、质押罚没与客户端脱敏共同保障。把机密性做成可选服务而不是全局强制，避免了把大部分供给排除在网络之外。

5.8 激励相容分析

造假可被抓、抓到即罚没，这只有在参数满足一组不等式时才成立。本节给出模型与约束，作为表 5.2 参数取值的依据。

5.8.1 服务商：作弊的期望收益

设服务商通过一次降级执行（以小模型冒充、跳过上游转发等）获得额外毛利 $\Delta > 0$。这里 Δ 是价差：声明旗舰模型的价格减去实际所跑模型的成本，再加上本不该收的那部分。作弊只有两种结局。以概率 p 被确认违约，收据作废、价差落袋不成，还要按质押额 S 的 σ 比例（$\sigma \in (0,1)$）被罚没；以概率 $1-p$ 未被发现，价差全额落袋。两种结局之外还有一笔固定开销 C：规避挑战的复杂度、维持假证据的成本，这笔钱不管抓不抓得到都要花。写成式子

$$\mathbb{E}[\text{cheat}] = (1-p)\,\Delta - p\,\sigma S - C. \tag{5.1}$$

诚实经营不发生成本 C，也不承担罚没，期望净收益就是正常毛利 Δ_h。让作弊不划算的条件是式 (5.1) 左端为负，移项即得

$$\mathbb{E}[\text{cheat}] < 0 \quad\Longleftrightarrow\quad p\,\sigma S + C > \Delta. \tag{5.2}$$

式 (5.2) 只约束作假这一侧。参与约束要另外成立：$\Delta_h > 0$，否则诚实服务商退出，网络没有供给，式 (5.2) 再漂亮也无人可罚。两条合起来才是完整的激励相容，治理调参不能只看其中一条。

检出概率 p 由三路发现机制合成，三路在一次作弊上互相独立地发挥作用，只要有一路命中就算被抓住。记审计员单位时间挑战强度为 λ_t、单次挑战检出率为 q_t，则审计员这一路的命中概率近似为 $\min(1, \lambda_t q_t)$（挑战强度足够高时必然撞上一次）；随机强制 ZK 抽查以概率 ρ_t 直接命中；调用方侧事后核验的命中概率为 p_{client}（下标 t 为保真等级）。三路都放过的概率是三者补集的乘积，故

$$p_t \;=\; 1 - \big(1 - \min(1, \lambda_t q_t)\big)\,(1-\rho_t)\,(1-p_{\text{client}}), \tag{5.3}$$

其中 p_{client} 通常很小但不为零，保留它是为了让客户端核验这一路的贡献在式子里可见。式 (5.2) 直接决定证明强度该怎么分级。高频低单价调用的 Δ 小，较低的 p_t 就足以让左端压过 Δ，Tier 0 够用；高价值调用的 Δ 大，要么抬高 p_t（Tier 1/2），要么抬高 σS，否则不等式不成立。一刀切的证明强度因此在经济上站不住：对小调用是浪费，对大调用不够。

同样的不等式给出准入质押的下界。作弊价差有个上界 $\Delta_{\max}$，由同类模型的市场价格差决定；把 p_t 与 σ 代进去解出 S，得 $S_{\min} > (\Delta_{\max} - C)/(p_t\sigma)$。下界随服务商声明的容量与单价走，全网一个常数会让小服务商多押、大服务商押不够。

ρ_t 在式 (5.3) 里以乘法形式进入 p_t，位置特殊。TEE 被攻破时审计员的 q_t 大幅下降，ρ_t 几乎独自撑起检出率。随机抽查的价值不在覆盖了多少调用量，而在这种退化场景下还能把作弊期望收益压回负值。

5.8.2 审计员：诬告与串通

审计员发起一次挑战也有两种结局。以概率 w 挑战成立：押金 b 退还，另按比例 β 分得罚没所得 σS，代价是构造与提交证据的成本 g。以概率 $1-w$ 挑战失败：押金 b

被扣，成本 g 照付。写出来

$$\mathbb{E}[\text{challenge}] = w\,\beta\,\sigma S - (1-w)\,b - g, \tag{5.4}$$

其中 w 为挑战成立的先验概率。对诚实服务商的诬告里 w 趋近于 0，期望收益落在 $-b-g$，注定亏本；对真实违约 w 趋近于 1，期望收益为正。押金 b 与成本 g 因此起的是筛选作用：把只敢打真目标的审计员留下，把骚扰性挑战挡在门外。b 的取值要高于一次虚假挑战的期望收益，具体见表 5.2。

串通场景（审计员与服务商合谋制造假挑战转移罚没）由裁决权分离抑制：赏金只在客观失败成立后支付，而客观失败的判定不经过审计员，合谋无法制造出「成立的挑战」。剩余风险是挑战资源被骚扰性消耗，由押金 b 的设定与挑战频率限制缓解。

5.8.3 验证人：无法寻租

验证人与服务商之间没有收益映射。验证人的收入来自出块奖励与协议费分成，服务收入只由用户付费决定，与谁验证无关（原则 2）。这条切断是设计出来的：若验证人能从某家服务商的调用量里分成，它就有动机偏袒。

剩下的可操纵空间只有两种动作。拒收合法收据，损失的是自己那份手续费，而且路由服务能从收据迟迟不上链这件事感知到，换不来好处；接受非法收据，触犯的是共识层的客观违约（双签一类），按共识规则罚没，与服务商罚没分开执行。两种动作都没有稳定收益，串通寻租在协议内找不到落点。

5.8.4 参数区间

表 5.2 给出建议参数区间。区间由不等式 (5.2)–(5.4) 约束，具体取值在测试网基准测试（对 $\Delta_{\max}$、C、g 的实测估计）之后由治理定稿。

参数之间存在联动：降低 σ 必须提高 p_t 或 $S_{\min}$；提高 β 会降低审计员门槛但增加骚扰挑战的收益；提高 ρ_t 直接抬高协议的证明成本。治理的职责是在这组不等式内移动参数，而不是单独调整某一个数字。

表 5.2　经济参数建议区间

参数	建议区间	定稿条件
罚没比例 σ	质押的 5%–20%（按等级）	测试网测得 $\Delta_{\max}$ 后按式 (5.2) 校准
审计赏金分成 β	罚没额的 10%–50%	使式 (5.4) 在真实违约下为正、诬告下为负
挑战押金 b	高于单次虚假挑战期望收益	与挑战成本 g 同量级，治理可调
准入质押 $S_{\min}$	随声明容量与单价分档	$S_{\min} > (\Delta_{\max} - C)/(p_t\sigma)$
随机抽查率 ρ_t	Tier 2 目标 0.1%–1%	随 zkML 成本下降上调；使 TEE 攻破场景下式 (5.2) 仍成立
协议费率 ε	结算额的 0.1%–1%	覆盖验证成本并形成正的质押收益来源
最大提交间隔 $T_{\max}$	目标 24 小时	平衡服务商聚合收益与调用方结算延迟

第六章 共识与链架构

6.1 独立 Layer 1 的依据

协议最初考虑过两条实现路径：在现有 EVM 链或 Rollup 上以合约集实现，或者自建主权链。最终选择后者，论证基于三条，均与机制本身而非生态偏好有关。

收据是协议级原语，不是应用。每张收据都要被签发、聚合、验证与结算，调用频次比普通 DeFi 交易高出若干个数量级。在通用链上以合约实现，每张收据都要承担 EVM 解释执行、通用验签与存储的开销；在自建链上，收据的验证与聚合由原生模块和预编译直接支持。两者在每张收据的摊销成本上相差数量级（估算见第 6.4 节），这决定了高频低单价调用能否成立。

安全模型必须按推理市场定制。原则 2（服务量不进入共识权重）与原则 3（只客观罚没）都是共识层规则：什么算证据、什么触发罚没、罚没比例如何执行，必须写进共识状态机。在别人的链上，这些规则要么无法表达，要么受制于对方的升级节奏。

链下热路径需要链的原生理解。「通道 + 链下接单 + 批量结算」要求挂单簿可被高频查询、通道可快速开设、只有完成的调用上链。这是一个完整的协议设计，不是若干合约的拼装；把它做成合约会把热路径拖回冷路径的节奏里。

需要说明代价：主权链意味着要自建验证人集合、自担安全预算、自管跨链桥。协议接受这一代价，理由是上述三条在合约路径下无法折中；相对地，生态启动期通过兼容 EVM 的合约层降低应用迁移成本。

6.2 纯质押共识

共识采用纯权益证明：出块权重只与质押额度相关，与服务商的调用量、收入、用户评价无关。这一设计刻意切断两条常见的激励通道：

- 用刷量换取记账权。服务量不进共识权重，刷量不产生共识收益，伪造调用量换不到记账地位，也换不到分配给验证人的协议费之外的收益。
- 用评分操纵收益分配。验证人没有质量评分权，服务商收益只来自用户付费，评分这张牌在协议内没有落点，操纵评分拿不到额外收入。

罚没只由客观失败触发：双签、长期离线、收据验证失败却仍打包、应答挑战时拿不出转发证据。协议不设按质量评分罚没之类的主观规则；若某类问题无法用客观证据判定，它就不属于共识层。

6.3 原生模块与预编译

协议内核由五个原生模块构成，依赖顺序为 `provider` → `proof` → `receipt` → `channel` → `market`：前两者定义服务商生命周期与罚没条件，后续模块才有意义。

表 6.1　原生模块职责

模块	职责
`provider`	服务商注册、质押、远程证明校验、退出与罚没执行
`market`	链上可查询挂单簿：模型、单价、证明等级、容量参考值、机密级声明
`channel`	调用方与服务商之间的支付通道：开设、预锁、结算、关闭
`receipt`	VSR 收据的签名验证、调用链授权校验、聚合与结算
`proof`	保真证明验证、隐蔽挑战登记、二分争议裁决、ZK 抽查执行

两条预编译路径承担高频计算：DCAP 类远程证明验证（Tier 2 注册与抽查用）与批量签名验证（聚合收据结算用）。预编译把这两类计算从 EVM 解释执行中剥离，是收据摊销成本下降的主要来源。

应用合约层（EVM 兼容）部署在原生模块之上，承载身份注册、分账规则、应用商店等业务逻辑。合约层可以读收据、调用结算接口，但不能改写收据语义与罚没规则。内核与应用的边界即原则 5。

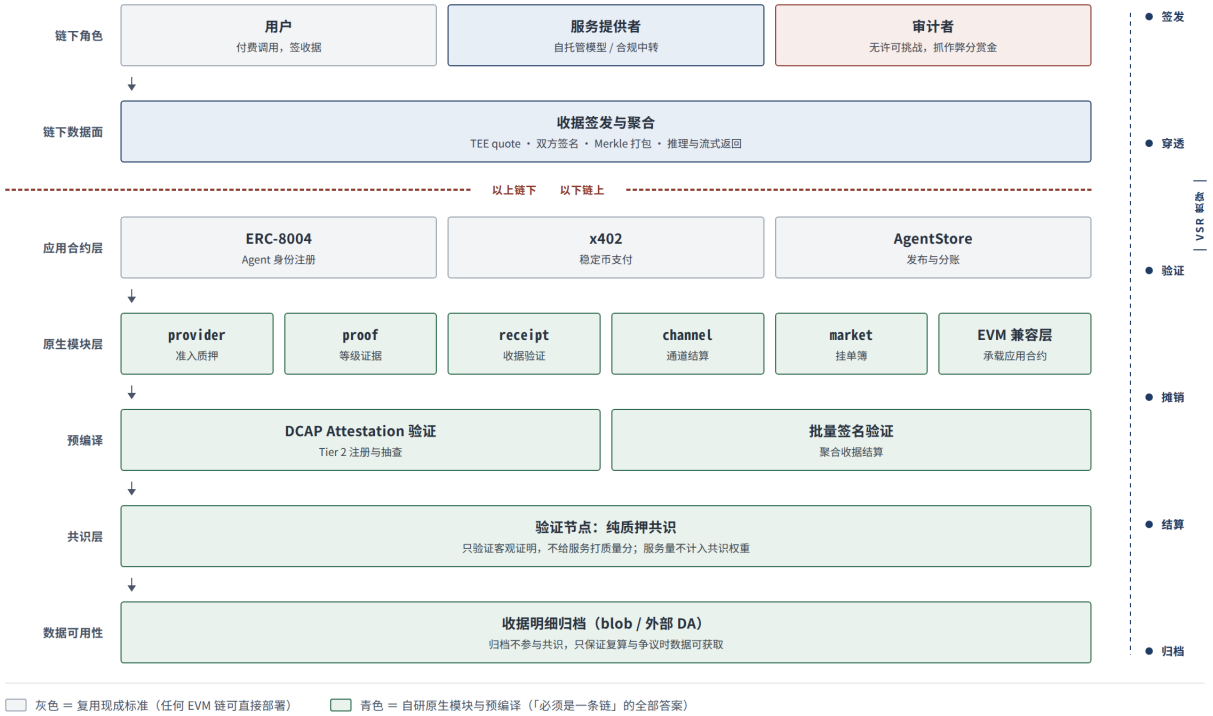


图 6.1　架构分层。灰色为复用的现成标准，青色为自研原生模块与预编译。收据是唯一穿透链下与链上的对象：链下签发与聚合，`receipt` 模块验证，`channel` 模块结算，DA 层归档明细。

6.4 性能预算

本节给出数量级估算，用于判断设计是否自洽。数值为推算而非实测，测试网阶段的基准测试将给出定稿数据。

收据的链上成本。一张收据的明文载荷约 150–300 字节（不含签名，数量级估算）。在 EVM 上以合约验证两张 secp256k1 签名，仅 `ecrecover` 一项即约 3,000 gas/次（数量级估算），加上存储与解释开销，单张收据的合约路径成本在 10^4–10^5 gas 量级。协议路径下，批量签名验证预编译把 N 张收据的验签摊销为常数次配对运算加 $O(N)$ 次哈希，Merkle 聚合后单张收据的链上写入摊销为一片叶子（约 32 字节加索引）。设计目标是把单张收据的摊销成本压到合约路径的 1%–10%，即下降一到两个数量级。

吞吐。设单个通道周期聚合 k 张收据、区块容量允许 B 次聚合提交，则结算吞吐约为 $k \cdot B$ 张收据/区块。以 $k = 10^3$–10^4、聚合提交数十次/秒计，协议目标区间为 10^4–10^5 张收据的结算/秒（设计目标）。该数字只覆盖结算，不覆盖推理；调用本身在链下，不受此约束。

延迟预算。热路径（Init 至 Issued）的延迟为

$$L_{\text{call}} = L_{\text{lookup}} + L_{\text{network}} + L_{\text{inference}},$$

不含区块间隔。收据的结算最终性为聚合提交后的区块确认（出块目标约 1 秒，亚秒级确定性最终性，定稿条件：测试网共识参数实测），与调用延迟是两个独立时钟。

最大提交间隔的取舍。$T_{\max}$（目标 24 小时）调和了两个相反的成本：服务商聚合得越久，摊销越低；调用方等待结算越久，资金占用越高。中间档位（如 1–6 小时）可由服务商按通道自选，$T_{\max}$ 只是上界。

6.5 内核刻意不做的事

以下三项是设计上的排除项，不是能力不足。排除的理由都指向同一个判据：进入内核会破坏可验证性或内核的最小性。

不做协议级智能路由

一次请求只发给一个服务商，一次会话只锁定一个服务商。协议放弃单点故障下的自动转移，换取协议逻辑的可验证与可推理；冗余、重试、多路比较由链下路由服务实现（第 8.1 节）。

不在内核做多方分账

分账规则随 Agent 商业模式快速变化，写进内核意味着每次规则迭代都是协议升级。规则留在合约层，调用链提供事实。

不强制 GPU TEE

硬件门槛会把大量供给排除在外。机密性与完整性是两种保证，分开提供：完整性由保真机制覆盖，机密性由可选的机密级服务覆盖。

第七章 代币经济学

代币名称尚未定稿（定稿条件：主网治理），本文以 LLM 记之。本章描述代币在协议中的职能与价值流，不构成任何形式的投资邀约；所有参数以主网治理定稿为准。

7.1 职能

LLM 在协议中承担四项职能，每一项都对应一类真实的服务需求，而非仅治理符号。

表 7.1 代币职能

职能	说明
调用支付	调用方以 LLM 或经兑换的稳定币支付推理费用；稳定币路径经通道合约即时兑换
服务商质押	挂单前必须质押；客观违约即罚没，质押是准入条件也是威慑来源
审计员质押	挑战资格的抵押；挑战失败扣除，举证成立分享罚没赏金
验证人质押	出块权重来源（原则 2），获取出块奖励与协议费分成
治理	协议参数调整（表 5.2）与模块升级的投票

支付媒介允许稳定币，质押与治理必须是 LLM。这一组合把计量单位的稳定与安全预算的同源分开处理：调用方不承担价格波动的结算风险，网络的安全预算仍然与代币价值绑定。

7.2 价值流

协议费是价值捕获的核心：每笔收据结算抽取比例 ε（目标 0.1%–1%），进入协议费用池，按规则分配给出块的验证人、协议金库与生态基金。图 7.1 给出价值流的走向：调用量增长抬升协议费收入，协议费提升质押收益，质押规模扩大推高造假成本并增加可信供给，进而吸引更多调用。



图 7.1 价值流。每一环都是协议内的真实交易或参数关系，不依赖投机性需求。

源与汇。表 7.2 按现金流方向汇总代币的来源与去向。协议的目标是让净收缩项（罚没销毁、费用沉淀）与调用量同向增长，使代币的净需求由真实使用驱动。

表 7.2　代币源汇

方向	项目	触发条件
需求（买方）	调用支付（LLM 直付路径）	每次结算
需求（买方）	质押锁定（服务商 / 审计员 / 验证人）	注册、挂单、出块
需求（买方）	治理锁仓	参与投票
供给（卖方）	验证人与委托人收益变现	出块奖励与费用分成
供给（卖方）	服务商收入变现	调用费结算
汇（净收缩）	罚没销毁（部分或全部）	客观违约
汇（净收缩）	协议金库沉淀	每笔结算的 ε
汇（净收缩）	争议押金扣除	挑战失败、骚扰性挑战

7.3 费用结构

一次结算涉及的费用科目如下，除协议费外均为市场定价：

- **调用费**。服务商自主定价，按模型、证明等级、机密级与否分档；价格发现由挂单簿竞争完成，协议不设价格管制。定价权留给市场，是因为同一模型在不同保真等级、不同供给形态下的成本结构不同，协议无从替它们定价。
- **协议费** ε。按结算额比例抽取，是验证人收益与金库的来源。费率是治理参数，目标区间 0.1%–1%。它不随调用方身份变化，也不作为收入调节工具，只承担协议运行的成本。
- **结算 gas**。批量结算的链上成本由提交方（服务商）承担，摊销后单张收据成本见第 6.4 节。由服务商承担而非调用方承担，是因为提交时机由服务商掌握，它可以选择在 gas 便宜时聚合提交。
- **争议成本**。挑战押金 b 与举证成本 g；挑战成立后押金退还，赏金来自罚没所得。成本的存在是为了让挑战不是免费动作，同时让成功的挑战有利可图，两端都不为零，审计才成为可持续的市场。
- **路由服务费**。链下商业协议，不进入收据结算（第 8.1 节）。路由收费是它与调用方之间的商业安排，收据只记录算力交付，不记载中介服务。

7.4 质押与罚没

质押分三类用途，彼此独立记账：

服务商质押

对应的是保真承诺。服务商声明能提供某个模型、某个证明等级、某个容量，质押就是这份声明的担保额度：被证实降级或伪造时，在这个额度内被罚没。准入下限

$S_{\min}$ 随声明容量与单价分档（表 5.2），声明越大、单价越高，可作弊的价差越大，需要的担保越多。罚没比例 σ 按保真等级取 5%–20%。罚没所得按 β 分成给举证审计员，其余进金库或销毁，赏金分成让举证成为有收益的市场行为。

审计员质押

对应的是挑战资格。挑战会占用验证资源，也会对服务商造成声誉与资金压力，押金是发起挑战的成本。额度与挑战频率上限挂钩，防止资本雄厚的一方用海量挑战淹没网络。挑战失败扣除，把诬告从免费选项变成有代价的选项。

验证人质押

对应的是出块权重。验证人拿的是共识层的地位，担保的是共识层的行为：双签、长期离线按共识规则罚没，与服务商罚没分开执行。分开是因为两者的失败判据不同：服务商失败是交付事实不符，验证人失败是共识行为越界，混在一个账本里会让判据互相污染。

委托的连带责任。委托人分享被委托方的收益，同时承担被罚没的连带风险。这一对称性是必须的：若收益可分享而罚没不连带，服务商可以他人的质押作为自己的安全预算，威慑失效。

7.5 价值捕获与风险

代币价值捕获依赖于一个可观测的关系：协议费收入随调用量增长，质押需求随协议费增长。若调用量增长不带动费用（例如 ε 被治理压到零）或质押收益不吸引资本（例如替代收益显著更高），这一关系在对应环节断开。

风险沿价值捕获的三个环节分布，每一处都对应一条参数约束。代币价格波动影响质押的实际安全预算，罚没比例因此以计价单位而非代币数量定义，参数上要留缓冲。稳定币直付路径会分流 LLM 的支付需求，价值捕获主要依赖质押与费用沉淀而非支付媒介本身。治理参数若被短期利益绑架（降费率、降罚没），会直接削弱激励相容条件 (5.2)，关键参数的调整范围因此写进治理规则，调参依据是测试网基准数据。

第八章 合约层的 Agent 经济

第 1.2 节把 Agent 经济定位在合约层。本章给出该层的三个构件：路由服务、多方分账、治理边界。它们的共同点是全部建立在收据链提供的事实之上，自身不定义调用是否发生。

8.1 路由服务

路由服务面向调用方提供统一接口（可实现为 OpenAI 兼容格式），在链下完成「查挂单 → 选服务商 → 发请求 → 失败重试」的循环。它是协议之上的商业层，不是协议组件，三条属性由协议边界保证：

非托管

路由只编排信息，不经手资金。支付通道由调用方与服务商直接建立，路由服务无法挪用、冻结或延迟结算。这条属性是路由能作为商业层的前提：若路由代收代付，它就重新变成聚合平台，协议在第 2.3 节列出的资金托管缺口会从后门回来。

可竞争

任何人都可以运营路由，无许可。竞争优势来自健康度数据的新鲜程度与选商策略的性价比，不来自协议授权的特许地位。路由做的是选商，选商好坏是个可比较的商业问题，让它保持可进入比指定唯一入口更符合去中心化供给的结构。

收入隔离

路由的商业收入（订阅、API 接入、引流分成）是链下协议，不进入 VSR 结算，不参与罚没，也不影响服务商的保真等级。隔离保证路由没有动机通过改写结算结果来提高自己的分成，它赚钱靠的是选商质量，不是账本上的位置。

有能力直连协议的高级 Agent 可以绕过路由，自行查询挂单簿、管理通道。路由的存在降低了接入成本，不构成必经节点。

8.2 多方分账

考虑 Agent A 承接用户任务、调用 Agent B、B 调用模型服务商 C 的链路。三次调用各自生成 VSR 收据，通过 `rootCallId` 串成一条调用链。部署在合约层的分账合约读取该链，按 A、B 预先约定的规则分配收入。

分账规则是合约，不是内核（原则 5）。Agent 的商业模式（转发加价、按结果分成、订阅包量、多级分销）变化速度远快于协议升级节奏。把规则留在合约层，社区可以随时发布新的分账标准，而收据链提供的事实不变：谁在谁的授权下、以什么价格、调用了谁。

授权与预算约束。父调用方签发 `authToken` 时应包含子调用的额度上限与有效期。子收据结算时 `receipt` 模块校验令牌签名、额度与调用链一致性，超额部分不予结算。这一约束防止被调用方盗用父调用的授权透支预算；具体令牌格式见附录 A。

8.3 治理范围

治理可以调整的内容与不可以调整的内容同样重要：

表 8.1　治理边界

治理可调	**不可通过治理改变**
经济参数：σ、β、b、$S_{\min}$、ε、ρ_t、$T_{\max}$	收据的结算语义：收据即结算（原则 1）
新信任根接入：TEE 厂商、ZK 证明系统、DA 层实现	共识权重规则：服务量不进权重（原则 2）
费率与金库分配、生态基金用途	罚没的客观性要求（原则 3）
模块升级与新预编译引入	争议裁决由客观逻辑执行，不由人工评分

参数调整须以测试网基准数据为依据（表 5.2 的定稿条件），并对调整幅度设上下限，防止治理把激励相容条件 (5.2) 推到失效区。

第九章 成本优化：上下文管理与任务分配

收据结算回答买到的是不是声明的东西；本章回答同样的东西能不能更便宜。两条主线的先后关系在路线图里写死：结算跑通之前不做成本优化的工程化。在一个按账单结算、以次充好不受惩罚的市场上，省下的每一分成本都会被降级服务的价差吃掉。本章给出原理、目标区间与验收条件；标注为规划项的机制没有实现，其设计依据与不确定性一并写明。工程实施排在主网 Beta 之后，原理与规划不因实施延后而省略。

9.1 成本模型：重复 prefill 的结构

记账口径。一次调用的用户成本由两部分构成。记单位 token 价格为 π（本章不用 p，避免与第 五 章的检出概率撞符号），输出 token 数为 T_{gen}，则

$$C_{\text{user}} = \underbrace{\pi \cdot T_{\text{gen}}}_{\text{有效生成}} + \underbrace{\pi \cdot T_{\text{prefill}}^{\text{paid}}}_{\text{重复计费的输入}} . \tag{9.1}$$

$T_{\text{prefill}}^{\text{paid}}$ 是用户实际为之付费、却没有产生新信息的输入 token：上下文里已经出现过、却因缓存不可用而被重新计算的部分。中心化服务商靠前缀缓存把这一项压到接近零，钱由服务商自己出；去中心化供给没有这层缓存可借，模型实例散在不同节点上，KV Cache 互不相通，调用被调度到新节点、会话中途换模型、分叉重试，都要重新 prefill，账单落在用户头上。

放大系数。把式 (9.1) 除以有效生成那一项，得到成本放大系数

$$\alpha \;=\; \frac{T_{\text{gen}} + T_{\text{prefill}}^{\text{paid}}}{T_{\text{gen}}} \;=\; 1 + \frac{T_{\text{prefill}}^{\text{paid}}}{T_{\text{gen}}}. \tag{9.2}$$

$\alpha = 1$ 表示只为有效生成付费，多出来的部分全在第二项。优化目标因此写得很直白：把 $T_{\text{prefill}}^{\text{paid}}$ 压到与 T_{gen} 同量级，α 就落到 2 附近。对 Agent 形工作负载的 token 账实测中，这一比值在四类场景下被显著抬高（合成轨迹实测，非真实市场报价，口径声明见第 9.5 节）：

有效生成的平均长度在实测轨迹上约 407 token（合成轨迹实测），远小于上下文总长，Agent 负载的成本大头在输入侧。所以压 α 与降单价在经济上是同一件事的两端，而压 α 是软件问题，改上下文怎么排、任务怎么派就能动，不需要等供给侧降价。这也是成本优化能在本章单独成章的原因：它不依赖共识或市场的成熟度，只依赖上下文组织与调度质量，收益还能从收据的计费 token 统计里直接读出。

9.2 上下文管理原理

定义 3（段与段类）. 一次调用的输入序列按语义分为若干段 $s_1, \ldots, s_k$，每段带一个段类标签 $\ell(s) \in \{\text{SCHEMA}, \text{HISTORY}, \text{TOOL}, \text{SCRATCH}\}$：不变的系统提示与工具定义、追加

表 9.1　重复 prefill 的四类放大（合成轨迹实测，α 为相对有效生成的倍数）

场景	触发条件	α 实测	优化方向
全量重喂	新节点无任何可用缓存	约 3.94	段级选择性迁移
前缀位置不利	可复用段落在 scratchpad 中部	约 2.47	按可变性重排段序
会话中途切换	轨迹中段换模型实例	均值 3.45，最坏 7.05	切换点对齐段边界
分叉重试	分支共享父前缀但各算一遍	约 2.26	父前缀跨分支复用

式对话历史、工具输出、可被改写的中间推理。段的可变性与被复用概率由段类决定，不由长度决定。

三条设计原则，对应表 9.1 的四个场景：

原则 6（稳定段先行）. schema 与历史段优先复用、最后逐出；scratchpad 段默认不跨调用复用。依据是可变性：scratchpad 在会话中会被改写，复用它换来的是失效缓存。

原则 7（尾置易变段）. 段序安排使易变段落在序列尾部，稳定段落在前缀。前缀缓存按位置匹配，易变段前置会把它后面的全部稳定段拖出缓存命中区间。

原则 8（切换点对齐边界）. 模型或节点切换尽量落在段边界上，且优先复用切换点之前的稳定段，把必须重算的部分收敛到切换点之后的短尾。理由是中段切换会同时废掉前后两侧的缓存（表 9.1 第三行的放大来源）。

跨节点迁移的记账。从节点 A 的 KV 迁一段到节点 B，省下的是在 B 重喂这段的成本 $T_{\text{refeed}}^{\text{saved}}$，代价有两笔：段本身传过去的开销 T_{transfer}，以及目标侧仍要补算的残余部分 T_{residual}（注意力维数或位置编码对不齐时补不干净）。净收益 $\Delta = T_{\text{refeed}}^{\text{saved}} - T_{\text{transfer}} - T_{\text{residual}}$，三项必须一起算，只看节省会高估收益。迁移因此是逐段决策：只迁 $\Delta > 0$ 的段。跨模型场景下段级迁移的可行性取决于模型对（注意力维数、tokenizer、训练分布），不是无条件成立；这一项的不确定性记入第 十一 章。

9.3 决策模型的任务分配

闲散算力的供给特征是异构、波动、单点容量小：企业夜间负载、边缘节点、个人高配终端、改造设备。把这些接进推理市场，任务分配要回答的是一串小而离散的判断题：这个请求进哪一档、这个节点现在能不能接、要不要降级重试。这些都是结构化选择，而非开放生成。这类判断适合用 System One 型的轻量决策模型执行：输出结构化的 choice / score / 判定结果，延迟在百毫秒级，单次成本远低于一次推理；复杂生成仍

交给被调度的推理模型本身。2026 年公开的 System One 决策模型已把这类结构化判断做成独立产品形态（资料截至 2026 年 10 月）。

9.3.1 分配层的小模型化与部署下限

分配层要比被调度的推理模型再轻一个量级，用自持的小模型实现：结构化微调后驻留单卡，与推理节点并置运行。自持的直接原因是外部商业决策服务属于协议外的信任点与单点依赖，其可用性、定价与输出语义都不受本协议约束，把任务分配交出去与非托管原则冲突。成本结构同时收紧了部署条件：分配层必须便宜到不进用户账单，单次决策的目标开销不超过一次调用费用的 1%（设计目标，定稿条件：测试网基准），决策时延目标在百毫秒量级。

部署下限是 CPU 可跑。分配层的定位是决策层的基础设施，任何运营方（路由服务、社区节点、自托管的调用方）都应能自己跑起来，而不是向单一服务购买分配判断。若依赖单一服务，决策层本身形成新的中心化入口，与协议的定位相反。设计目标是小模型（建议十亿参数以内，内存 GB 量级，量化可选）在普通 CPU 上给出分配决策，时延目标秒级以内（设计目标，定稿条件：与 GPU 驻留版本的误判率差值有基准）。模型权重与推理代码开源，任何人可以复现同一决策函数；分配器版本随调用链留痕，分配决策可事后复核。

小模型的选型代价写在明处：结构化判断的准确率随模型缩小下降，CPU 推理会进一步拉长尾部时延，分布偏移下的误判会系统性偏向某类节点。硬规则前置（原则 9）与回退路径（原则 10）是补偿手段，不是误判率为零的证明。可选的部署形态是让分配器自身跑在闲散节点上：分配模型成为网络上的小额负载，其调用同样产生收据；这是成本优化阶段的试点项，不是协议要求。

9.3.2 分配决策的定义

定义 4（分配决策）. 分配器 D 读取请求状态 q 与节点状态向量 $\mathbf{n} = (c, \ell, v, r)$（容量、时延分位、可用性、历史保真记录），输出一个结构化决策 $D(q, \mathbf{n}) = (target, tier, fallback)$：目标节点、服务档位、失败时的回退路径。决策输出直接进入调度执行，同时作为记录进入调用链，供事后审计。

分配器不产生内容、不改写收据语义，它是收据产生之前的编排层。其误判的代价是浪费一次调度或一次重试，不是错误结算。这一边界是它能先于协议内核迭代的原因。

9.3.3 参照实现：Laya

该能力类别目前有闭源产品（Jev，TypeSafe），本协议不依赖闭源服务作实现基础。参照实现选定开源决策模型 **Laya**（Convai Innovations，资料截至 2026 年 10 月），按其公开接口与实测口径部署。Laya 采用编码器加决策头的结构，单次前向输出 choice / score / 判定三类结构化结果并附校准概率，输出形状与定义 4 的决策元组一致；权重

Apache 2.0、推理代码 MIT，满足上文对权重与推理代码开源的要求。经 ONNX 运行时执行时权重约 1.7 GB（fp32），官方给出 Apple 芯片 CPU 上三问约 140 ms 的实测（模型预热后），CPU 部署下限由参照实现直接满足。协议绑定的是该开源实现的接口与决策形状，权重本身可替换：若参照实现停止维护，按同一接口换入其他开源权重，定义 4 与调用链留痕格式不变。

9.3.4 接口映射与迭代路径

定义 4 的三元输出映射为三个类型化提问：目标节点（在候选节点集上做 choice）、服务档位（在 Tier 0/1/2 上做 choice）、回退路径（在预设回退集上做 choice）。每个回答携带校准概率，低于阈值时不采纳模型判断、直接走硬规则回退（原则 9、10）。Laya 的状态窗口上限是 512 token（官方口径，资料截至 2026 年 10 月），因此 q 与 $\mathbf{n}$ 序列化为特征摘要而非原始上下文：估计 token 数、模型类别、档位要求、地域约束，加节点的容量、时延分位、可用性与历史保真记录。分配器不读取生成内容，也无需读取。

迭代路径是用调用链上留痕的分配记录做结构化微调：以实际调度结果（是否触发回退、实测时延、节点失联与否）为标签，在成本优化阶段完成首轮微调与误判率基准。准确率与置信校准的对照基线是 Strands Decider 2B（AWS，2026 年 10 月 1 日发布，2B 级躯干加指针头，权重与训练脚本开源，官方给出 RTX 3090 中位约 115 ms、M3 笔记本小任务约 153 ms 的本地实测）；该模型作对照基线，不作运行时依赖。若参照实现的误判率超出验收阈值，按接口换权重，协议语义不动。

9.3.5 分配原则

原则 9（决策优先，执行放权）. 硬规则（价格上限、证明等级下限、地域约束）先于模型判断执行；决策模型只在规则围出的空间里选择。规则可审计，模型判断可回溯（决策记录随调用链留存）。

原则 10（闲散算力只承接可降级任务）. 闲散节点承接的调用必须带明确的回退路径：节点失联时请求转回常驻节点，用户侧表现为时延波动，不表现为结果缺失。闲散算力的价值是把边际成本打下来，不是把可靠性打下去。

9.4 与结算层的接口

成本优化是增值层，不改收据语义。接口约束给出三层与底层之间的边界：省下来的钱怎么记账、闲散节点要不要另立规矩、分配决策要不要进结算。

(1) **分配记录可审计但不入结算。**D 的输出随调用链留痕，供路由服务调优与争议回溯，不作为结算依据。结算只认收据。这样切是因为分配是策略，策略会有错；策略出错时用户损失的是性价比，不应该连带影响钱货两清。把分配记录挂进结算，等于让一个可错的模块有能力改写账目。

(2) **闲散节点走同一保真等级体系**。节点来源（常驻 / 闲散）不降低保真要求；Tier 等级、挑战与罚没对所有供给方一致执行。闲散算力的价值在价格，不在门槛更低；若为它另立一套宽松标准，价差会集中在最不可信的那一段供给上，协议的保真承诺随之失去统一含义。

(3) **省下的成本可计量**。收据记载实际计费 token 数，α 的改善可以直接从收据链上汇总，不需要额外的信任。成本优化是否生效、生效多少，由同一套收据说话，不由实现方宣称。这一条把优化从工程叙事变成可核对的统计量。

第 3 条是本章与第 四 章的接缝：成本优化的收益以收据字段的统计结果为准，口头宣称不构成证据。

9.5 验收指标与口径声明

目标区间。在真实 Agent 轨迹上，设计目标是把 α 从实测的 3–7 区间压到 2 以下（段级迁移与尾置生效），闲散算力承接的调用占比、以及分配器的误判率（触发回退的比例）在测试网阶段给出基准后定稿。上述均为设计目标，不是已实现结果。

口径声明。表 9.1 的数字来自合成轨迹的 token 账核算（数学解题文本构造的 Agent 形会话），是代理指标，不是真实 Agent 服务负载的测量，也不是市场报价。真实轨迹上的复测是成本优化工程化的前置条件，排在路线图第 十 章成本优化阶段的退出条件里。本文对该组数字的使用仅限于证明放大的存在与优化方向，不用于宣称具体节省比例。

第十章 路线图

路线图以「阶段退出条件」而非日历日期组织。日期在测试网基准完成前不作承诺；每个阶段的完成判据是可验证的交付物。表 10.1 给出五个阶段。

排序原则只有一条：**结算先行，成本优化随后**。收据与结算没有跑通之前，成本优化的收益无法计量、无法归因、也无法防止被中间方吸收。省下的开销落在谁身上取决于结算事实，不取决于优化本身。因此成本优化整段排在主网 Beta 之后，但其原理与设计目标写在第 九 章，不因实施延后而省略。这部分规划说明的是协议在结算跑通之后还剩哪些问题、准备解决到什么程度。

表 10.1 阶段与退出条件

阶段	交付物	退出条件
测试网（结算）	五个原生模块上线；开源权重自托管服务商接入；VSR 结算跑通	端到端调用与结算稳定运行；确定性复算在支持的算子集上给出误判率数据
主网 Beta（结算）	审计员挑战与罚没收效；首批路由服务；批量结算与 DA 归档	参数区间（表 5.2）以基准数据校准并锁定；通道与争议机制经审计
主网（结算）	闭源中转 Tier 2（许可制）；机密级服务；第二家 TEE 信任根	第二信任根接入完成；跨厂商降级预案至少有实现原型
成本优化	真实 Agent 轨迹的 α 复测；段级上下文管理（原则 6–8）；基于 Laya 的分配器原型与回退路径；闲散算力接入试点	真实轨迹上 α 复测完成且口径公开；分配器误判率与回退成功率有基准数据；闲散节点试点未出现保真等级降级
生态扩展	分账合约标准；Agent 应用商店；递归结算旗舰演示	分账标准由第三方独立实现并通过兼容性测试

旗舰演示。生态扩展阶段的旗舰演示是递归结算：一次用户任务触发 A→B→C 的调用链，三张收据、一次分账合约执行、全程无人工干预。该演示验证的是收据链、授权令牌与合约层分账三者的衔接。

成本优化阶段的性质。该阶段的交付物是可计量的 α 改善与分配器基准，不是新协议语义。它不引入新的结算对象、不改收据字段、不增加信任假设；任何声称成本优化机制已生效的表述，都必须以该阶段的退出条件数据为依据。

刻意后排的事项。跨厂商 TEE 失效的一致裁决（第 5.5 节）与大模型 zkML 常态化证明排在旗舰演示之后。两者都有明确的技术不确定性，提前承诺只会换来错误预期。

第十一章 局限与开放问题

本章汇总协议当前无法完全解决的问题。与其在机制章节用乐观表述掩盖，不如把边界写清楚：设计目标、已知缺口、以及缺口的可能闭合路径分开陈述。

11.1 保真机制的边界

确定性复算的环境一致性。「逐位一致」的判定只在同一算子实现、同一执行顺序、同一数值语义下成立。浮点归约顺序、原子加、非确定性算子（部分注意力实现、某些融合核）都会破坏逐位一致性。协议的处理是：把可确定性执行的算子与模型范围做成清单，清单内的判定是二值的；清单外的模型不能挂 Tier 1 复算档，只能降级或走 Tier 2。清单本身的维护、以及跨硬件（不同 GPU 型号、驱动版本）是否能保持同一数值结果，目前没有完整答案。跨硬件一致性可能需要把「执行环境哈希」写进收据，使复算只在同一环境类内被要求。

统计指纹的定位。top-k 对数概率分布等统计指纹缺少可靠的容差校准方法，因此只作为触发怀疑的辅助信号，不作为罚没依据。这削弱了 Tier 1 对「同分布不同权重」类作弊的检出能力：若作弊者找到一个输出分布接近的替代模型，确定性复算不适用于该场景（因为它本身就不是同一模型的确定性重放）。该缺口由质押威慑与 Tier 2 覆盖，但不为零。

11.2 证明机制的边界

zkML 的成本现实。对大模型的每一次推理生成零知识证明目前不可行，随机强制抽查因此只能覆盖低抽查率 ρ_t。ρ_t 过低时，作弊的期望收益可能仍然为正，尤其是单价极高的调用。协议的应对是高价值调用要求更高质押或强制 Tier 2，但这是参数补丁，不是根本解决。根本解决依赖 zkML 证明成本的持续下降，协议只保证验证接口兼容未来的证明系统。

二分争议的单步验证。争议收敛到单个计算步骤后，链上需要验证这一步的转移函数。对复杂算子（大矩阵乘、融合核），「单步」本身可能仍昂贵到需要再套一层证明或专用电路。乐观路径假设单步验证成本可控，该假设在算子粒度设计上需要大量工程验证，目前只有思路没有基准。

TEE 信任根的单点性。Tier 2 目前依赖单一厂商。该厂商的侧信道漏洞、供应链事件或证书撤销会同时影响所有 Tier 2 服务商。多厂商支持排在路线图上，但「某厂商失效时如何在不停机、不误罚诚实服务商的前提下降级运行」尚无完整方案。可能的机制包括按 attestation 类型分级降级、挑战期延长、治理触发的紧急参数调整，均未定稿。

闭源上游的转发证据。Tier 2 对闭源中转要求 TEE 内记录 TLS 会话证据，拿不出即视为客观违约。这一机制能证明「转发动作发生在 enclave 内且会话可审计」，不能证明「上游返回的内容确实由声明的模型生成」。后者依赖上游服务商的诚实，属于协议之外的信任。调用方对闭源供给的保真预期不应高于此。

11.3 成本优化的边界

α 数字的口径。表 9.1 的放大系数来自合成轨迹的 token 账，不是真实 Agent 服务负载的测量，也不是市场报价。合成轨迹从数学解题文本构造 Agent 形会话，缺少真实工具输出、人机等待间隔与跨模型级联的分布特征。在真实轨迹复测完成之前，任何具体节省比例的表述都超出证据范围；本文只主张放大现象存在、优化方向明确。

段级迁移的跨模型可行性。原则 6–8 在同一模型同一实例内有缓存机制支撑；跨模型（不同权重、不同 tokenizer）场景下，段级 KV 的可迁移性取决于模型对的注意力结构相似度，不是无条件成立。部分模型对上线性映射会急剧退化，切换点对齐也无法补救。协议的立场是把跨模型迁移当作逐段可选项（$\Delta > 0$ 才迁），不承诺迁移成功率。

分配器的错误模式。决策模型分配器的误判代价是浪费调度或触发回退，不是错误结算，但误判的形态仍需基准支撑。可降级任务被派给失联闲散节点时，时延恶化；决策模型自身的路由偏差（对某类请求系统性偏向特定节点）会形成隐性负载倾斜。这两类形态都要在成本优化阶段给出测量，而不是靠原则约束。闲散算力的可靠性分布（重尾时延、中途退出）本身缺少公开数据，分配器的回退路径目前只有设计没有验证。

参照实现的上游依赖。分配层参照实现（第 9.3 节的 Laya）是第三方开源项目，其上游演进节奏、许可证变更与训练数据治理不受本协议控制。协议的立场是绑定接口与决策形状而非具体权重：接口含三个类型化提问的输入输出模式、校准概率字段与调用链留痕格式，换权重不动这三样；对照基线（Strands Decider 2B）的输出形状与之兼容，替换路径已知。另一类代价在特征侧：状态窗口把 q 压缩为特征摘要，摘要未覆盖的请求属性（例如罕见的工具输出形态）不进入分配判断，此类盲区的出现频率需要在真实轨迹上测量，目前没有数据。

成本优化与结算正确性无因果关系。省 token 不使收据更可信，收据可信也不自动使 token 更省。任何把两者捆绑宣传的解读都超出了设计：本协议的两个保证是独立验收的（第 十 章的阶段划分即为此）。

11.4 经济机制的边界

参数校准依赖外部测量。激励相容条件 (5.2) 中的 $\Delta_{\max}$（作弊毛利上界）、C（作弊成本）、g（挑战成本）是市场变量，协议无法直接观测，只能通过测试网实验与市场结构估计。参数表 5.2 给出的是区间，不是最优值；错误的校准会同时导致「罚没过松」与「误罚诚实服务商」。

非理性与合谋的残余风险。假设 4 不成立时（不计收益的破坏者、政治性攻击），协议只能限制其自身损失规模（质押上限、罚没上限），无法阻止行为本身。多服务商合谋抬价或联合不响应挑战，属于市场结构问题，协议内没有反垄断机制。

治理捕获。关键参数（σ、ε、β）由治理调整。若治理权被短期利益俘获，可能把激励相容条件推到失效区（例如大幅降低罚没比例）。缓解手段是参数调整幅度限制与调整延迟，属于治理设计范畴，本文未展开。

11.5 协议与工程的开放问题

收据共签的公平交换。VSR 需要调用方与服务商双方签名，但双方无法原子地交换「输出」与「签名」：服务商先交输出再等签名，调用方可以在拿到结果后拒绝共签、不产生收据；调用方先签名，服务商可以拒交输出。支付通道解决的是拒**付**（资金已预锁），不解决拒**签**（收据无法形成）。可能的路径包括服务商单边收据加超时生效、由 TEE 内的原子交换保证、或通道合约接受一方签名加超时窗口的默认裁决，各有取舍，尚无定稿。在该问题闭合之前，「双方签名收据」在恶意调用方场景下是不完整的结算保证，Tier 0/1 的经济分析也依赖调用方有动机共签（正常商业关系下成立）。

支付链与收据链的结算原子性。x402 通道上的稳定币支付可以发生在任一 EVM 链上，而收据结算发生在 LLMChain。两者的原子性（资金在支付链锁定、收据在结算链验证通过后原子释放，或者桥中继的信任假设）本文未展开。若引入跨链桥，桥的托管风险会部分抵消非托管通道的设计初衷；若要求资金与收据同链，则 x402 的链选择被约束。该问题影响部署拓扑而非协议语义，但决定了早期网络的资金形态，列为主网 Beta 前必须回答的问题。

以下问题已有方向但没有结论，按影响面排列：

(1) **跨厂商 TEE 失效的一致裁决**。见第 5.5 节。

(2) **执行环境指纹的规范化**。哪些软硬件属性进入「环境类」定义，决定了确定性复算的可移植性（见 11.1 段）。

(3) **挑战不可区分性的工程边界**。假设 5 要求挑战请求在所有可观测侧信道上与真实调用一致；分布式计时、流量分析是否构成区分手段，需要红队验证。

(4) **随机数信标的抗偏置实现**。ZK 抽查的选号若可被出块者预测或偏置，串通方可以避开抽查；需要 VRF、提交与揭示或外部信标的具体选型，假设 2 在实现层面临考验。

(5) **收据聚合的证明系统选择**。批量签名验证与 Merkle 归档的具体方案（曲线、聚合方式、DA 层）影响性能预算一个数量级以上，见第 6.4 节。

(6) **通道容量与流动性**。高频低单价调用要求通道长时间预锁资金，资金占用的经济性（尤其对小额调用方）可能催生通道流动性服务商，其风险模型尚未分析。

这些缺口不阻塞测试网与主网 Beta 的主线交付，但都写明在路线图的后排位置

（第 十 章）。任何把本协议理解为「已解决推理保真问题」的解读都超出了设计范围：协议解决的是服务事实的可验证与结算的自动执行，并且只在本章声明的边界内成立。

附录 A VSR 收据规范

本附录给出收据的字段级语义、验证流程与递归授权令牌的最小格式。最终字节级编码（如 SSZ 或 RLP 变体）在测试网阶段随实现定稿。

A.1 字段语义

表 4.2 列出核心字段，补充约束如下：

- `callId` 由调用方生成，要求在链内唯一（建议取签名者地址、时间戳与随机数的摘要）。重复的 `callId` 被 `receipt` 模块拒绝。
- `modelHash` 对开源自托管是权重文件的哈希；对闭源中转是中转声明的哈希（含上游 endpoint 与模型名），其真实性上限见第 11.2 节。
- `inputDigest` / `outputDigest` 为原始字节的密码学摘要，摘要函数由收据版本指定。摘要的明文只在争议或复算时由举证方提交。
- `proofTier` 决定结算校验路径与罚没规则；收据声明的等级不得高于服务商挂单声明的等级。
- `expiresAt` 默认为签发后 $T_{\max}$ 内；逾期未提交的收据失效。

A.2 验证流程

`receipt` 模块对每张待结算收据按顺序执行：

V1) 格式与版本校验：`chainId`、`version`、字段长度合法；

V2) 防重放：`callId` 未使用，且在 `expiresAt` 之前；

V3) 签名校验：`sigCaller`、`sigProvider` 均有效且覆盖全部字段；

V4) 通道校验：结算金额不超过通道未结算余额；

V5) 等级校验：`proofTier` 不高于挂单声明等级，且等级所需附件齐备（如 Tier 2 的 attestation 引用）；

V6) 递归校验：若 `parentCallId` 非空，`authToken` 校验通过；

V7) 结算：按 `amount` 划转，扣除协议费 ε，更新通道余额。

任一步骤失败即拒绝该收据；V5 失败触发服务商罚没流程（进入 Disputed）。

A.3 授权令牌

递归调用中，父调用方在发起子调用前签署授权令牌，最小字段集为：

$$authToken = \big(rootCallId,\ parentCallId,\ scope,\ maxAmount,\ expiresAt,\ \sigma_{\text{parent}}\big),$$

其中 $scope$ 限定可调用的服务商或模型类别，$maxAmount$ 限定子调用额度上限。子收据结算时校验令牌签名、额度与调用链一致性，超额部分不予结算。

附录 B 术语表

VSR

Verifiable Service Receipt，可验证服务收据。协议内唯一的链上结算对象。

调用 Call

一次由调用方发起、由服务商执行的推理服务，包含输入、输出、模型声明与价格。

调用链 Call chain

以 `rootCallId` 为根、由 `parentCallId` 关联形成的调用树，是多方分账的事实依据。

保真 Fidelity

执行与声明一致的程度：是否发生、是否运行在声明模型上、是否按约定价格计费。

Tier 0/1/2

保真等级，见表 5.1。

确定性复算

在受约束的算子实现与执行顺序下重放推理，要求输出逐位一致。

隐蔽挑战

审计员以真实调用形式发起的探测请求，与真实调用不可区分。

二分争议

双方对执行轨迹逐轮对分、收敛到单步后链上验证的交互式裁决。

客观罚没

由可机器判定的失败触发的罚没，不含主观评分。

挂单簿

`market` 模块维护的持久服务目录，不同于交易内存池。

热路径 / 冷路径

链下完成的选择、付款、执行 / 需要上链确认的结算与通道操作。

算力收据

VSR 的定位表述：收据记载的是算力交付事实，不判断调用方是否为 Agent。

α（成本放大系数）

$(T_{\text{gen}} + T_{\text{prefill}}^{\text{paid}})/T_{\text{gen}}$，见式 (9.1)。

段 Class

输入序列的语义分段（schema / history / tool / scratch），决定复用与逐出次序，

见定义 3。

决策模型

输出结构化判断（选项、打分、判定）的轻量模型，用于任务分配而非内容生成，见定义 4。

Laya

分配层的参照实现 (Convai Innovations)，开源决策模型，编码器加决策头，ONNX 部署，见第 9.3.3 节。

闲散算力

波动、异构、单点容量小的供给（夜间负载、边缘节点、个人终端），只承接可降级任务。

附录 C 参考文献

[1] G. Wood. Ethereum: A Secure Decentralised Generalised Transaction Ledger. Yellow Paper, 2014.

[2] J. Teutsch and S. Reitwiessner. A Scalable Verification Solution for Blockchains. arXiv:1908.04756, 2019.

[3] J. Poon and T. Dryja. The Bitcoin Lightning Network: Scalable Off-Chain Instant Payments. Technical Report, 2016.

[4] H. Kalodner, S. Goldberg, S. Micali, and A. Vipul. Arbitrum: Scalable, Private Smart Contracts. USENIX Security Symposium, 2018.

[5] Gensyn Network. Gensyn Protocol: A Scalable Compute Protocol for Machine Learning. Whitepaper, 2023.

[6] ezkl Project. ezkl: A Library for Creating Proofs of Model Inference. `https://github.com/zkonduit/ezkl`, 2023.

[7] Overclock Labs. Akash Network: A Secure, Transparent, and Decentralized Cloud Computing Marketplace. Whitepaper, 2020.

[8] Opentensor Foundation. Bittensor: A Peer-to-Peer Intelligence Market. Whitepaper, 2021.

[9] Coinbase. x402: Reviving HTTP 402 for Internet-Native Payments. Protocol Specification, 2025.

[10] Ethereum Foundation. ERC-8004: Trustless Agents. Ethereum Improvement Proposals, 2025.

[11] M. Al-Bassam, A. Sonnino, V. Buterin, and D. K. Moura. Fraud and Data Availability Proofs: Maximising Light Client Security and Scaling Rollups with Minimal Overhead. Whitepaper, 2019.

[12] V. Buterin and V. Griffith. Casper the Friendly Finality Gadget. arXiv:1710.09437, 2017.

[13] Intel Corporation. Intel SGX ECDSA/DCAP Attestation Technical Details. Technical Documentation, 2023.

[14] Advanced Micro Devices. AMD SEV-SNP: Strengthening VM Isolation with Integrity Protection and More. Technical White Paper, 2020.